# Customer Intelligence

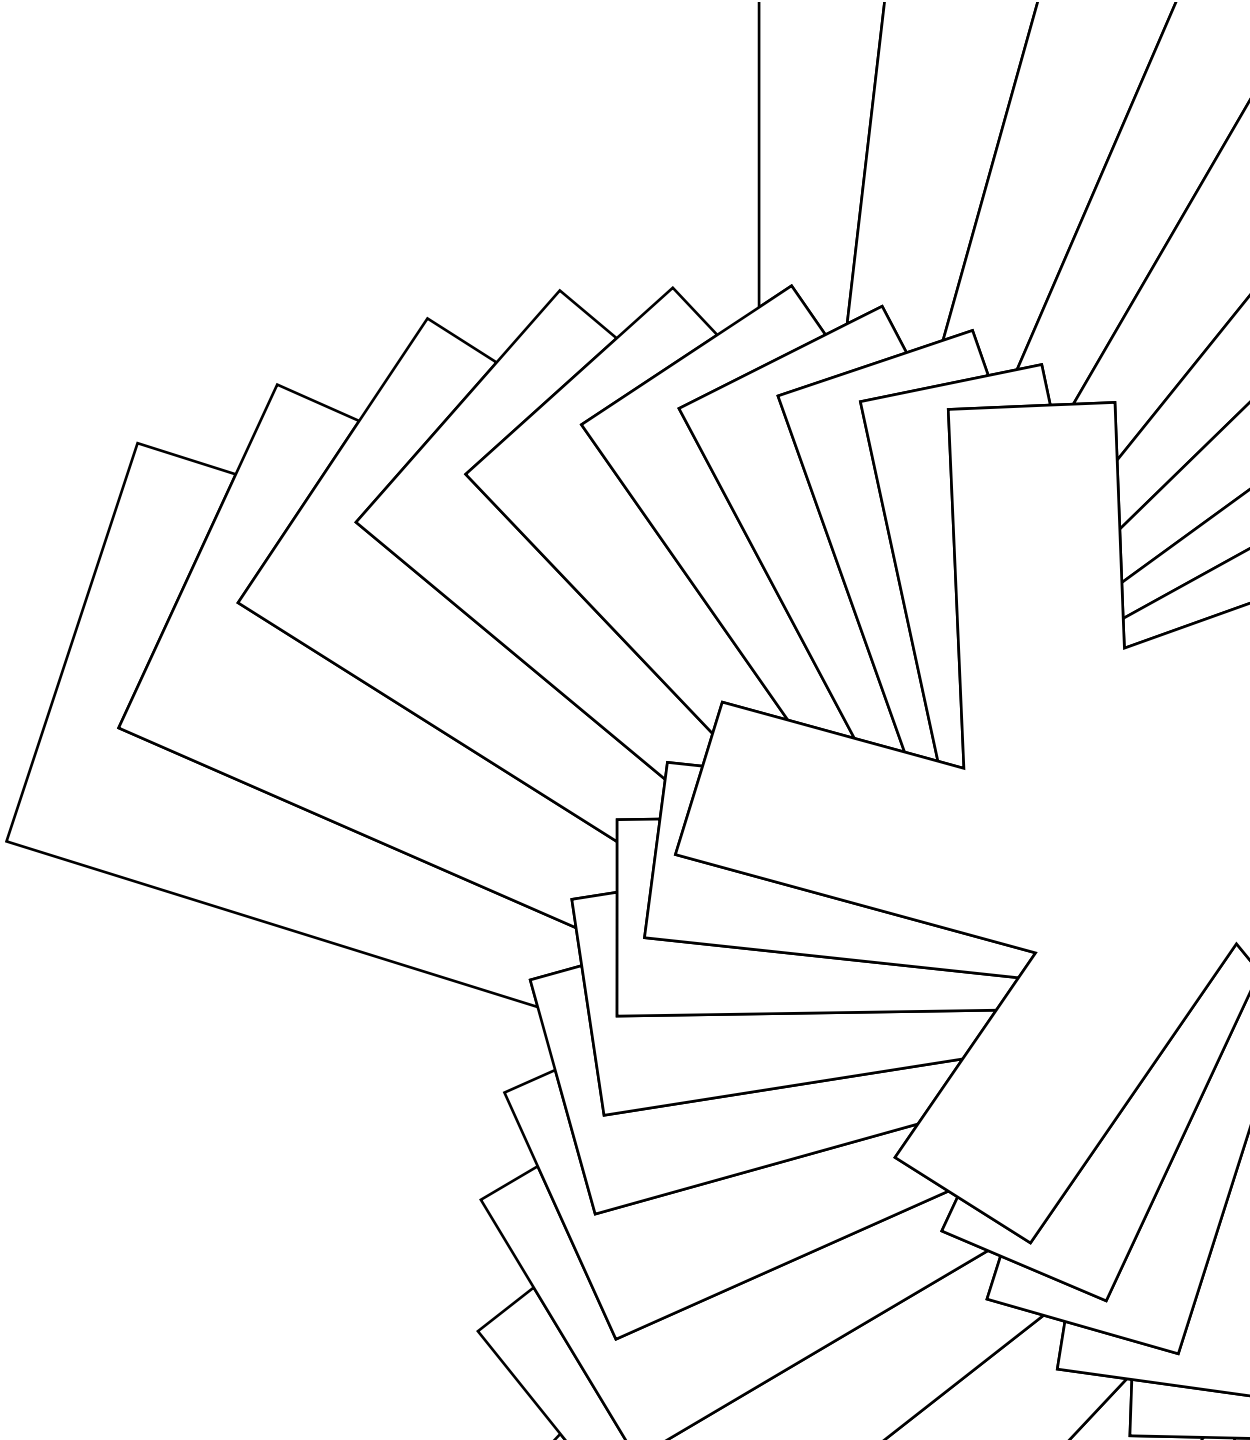
## Clase 1 · Construir la representación del cliente

**Asignatura:** Inteligencia Artificial para la personalización y experiencia de cliente

**Docente:** Álvaro de la Riva

unie*
Universidad

Planeta Formación y Universidades



# Tres preguntas aparentemente sencillas

**1**

¿Cuántos clientes tenemos?

**2**

¿Cuáles son nuestros mejores clientes?

**3**

¿A quién deberíamos escribir la semana que viene?

Dos años de ventas: algo más de un millón de líneas de factura. ¿Se responde en una tarde?

# ¿Cuántos clientes creéis que tenemos?

**¿QUÉ ESPERÁIS?**

Dos años de ventas, algo más de un millón de líneas de factura. ¿Cuántos clientes creéis que tenemos? ¿De qué depende?

Vuestras respuestas

# Hoy construimos la tabla de cliente




## Lo que te llevas

### customers.parquet

Una fila por cliente, once variables, a fecha 2011-12-10

### Diccionario de variables

Qué significa cada variable, cómo se calcula y para qué se usa

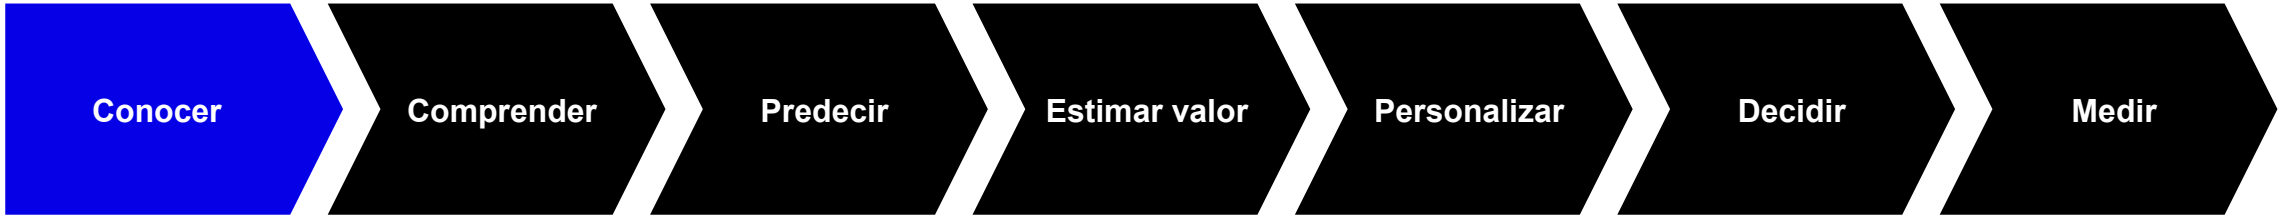
# Customer Intelligence y mapa del curso

Bloque B

unie*
Universidad

Planeta Formación y Universidades

# La asignatura es una cadena, no una lista de algoritmos




**I. Conocer y comprender**
Clases 1–5

**II. Predecir**
Clases 6–8

**III. Personalizar**
Clases 9–13

**IV. Decidir**
Clase 14

Hoy: el primer eslabón. Ningún algoritmo, solo la materia prima de todos los demás.

# Segmentar, predecir, recomendar y decidir no son lo mismo

| Tarea | Pregunta | Resultado | Clase |
|---|---|---|---|
| **Segmentar** | ¿Qué tipos de clientes hay? | Un grupo por cliente | 2 |
| **Predecir** | ¿Qué hará este cliente? | Un score por cliente | 6–8 |
| **Recomendar** | ¿Qué producto le interesa? | Una lista de productos por cliente | 9–13 |
| **Decidir (Next Best Action)** | ¿Qué hacemos ahora con él? | Una acción por cliente | 14 |

Las tres primeras **alimentan** la cuarta.

Las clases 3–5 (journey, texto y Voice of Customer) sirven para comprender al cliente: dan señales que alimentan estos cuatro resultados.

# ¿Qué tarea es cada encargo?

**PREGUNTA AL AULA**

## ¿Segmentar, predecir, recomendar o decidir? ¿Qué tarea es cada encargo?

**Cuatro encargos de marketing**

(a) Agrupad a los clientes en perfiles para adaptar el tono de cada campaña

(b) Anticipad qué clientes dejarán de comprar el próximo trimestre

(c) Proponed a cada cliente un complemento de lo que ya compró

(d) Decidid a qué clientes en riesgo merece la pena llamar, contando lo que cuesta

Vuestras respuestas

# Personalizar no es solo recomendar

| | | | |
|---|---|---|---|
| **Retener** | **Ofrecer** | **Hacer cross-selling** | **Reactivar** |
| **Elegir canal y momento** | **Recomendar** | **No hacer nada** | |

Churn, CLV, propensión, recomendación y Next Best Action son piezas de un mismo sistema.

# Todas las clases terminan igual

| Métrica técnica | Interpretación | Decisión | Limitación | Guardrail |
|---|---|---|---|---|
| Una parte de las ventas no tiene cliente | Esas compras no se pueden atribuir a nadie | Construimos el perfil solo con clientes identificados | Infravalora a quien a veces compra sin identificarse | Todo informe indica qué parte de las ventas cubre la tabla |

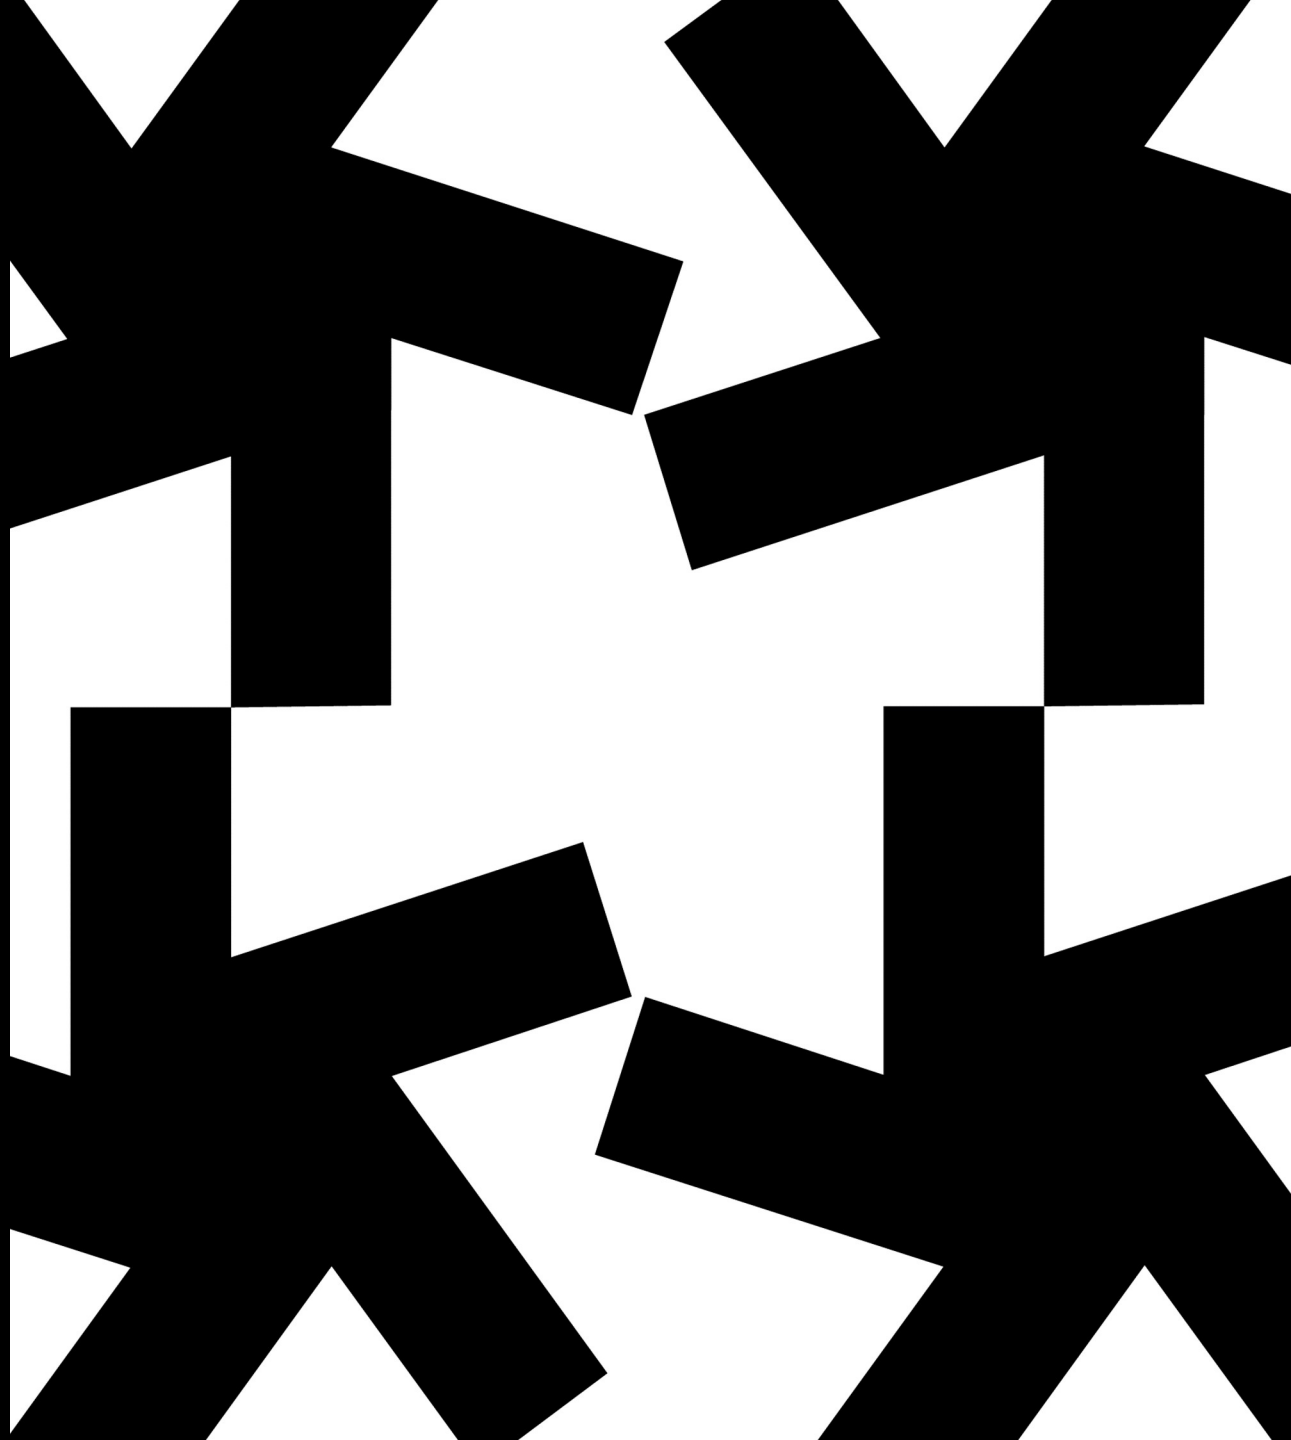
Ejemplo de esta clase: la cobertura del identificador de cliente.

# Cómo se representan los datos del cliente

Bloque C

unie*
Universidad

Planeta Formación y Universidades



# Cinco entidades describen casi cualquier problema

**Cliente**

customer_id, country

**Evento**

Cada línea de factura

**Producto**

stock_code, description, price

**Canal**

No aparece: todo es online

**Acción**

No aparece: solo registra lo que hace el cliente

En Online Retail II

Pregunta guía ante cualquier tabla: **¿qué representa cada fila?**

# ¿Cuánto vale esta factura?

**PREGUNTA AL AULA**

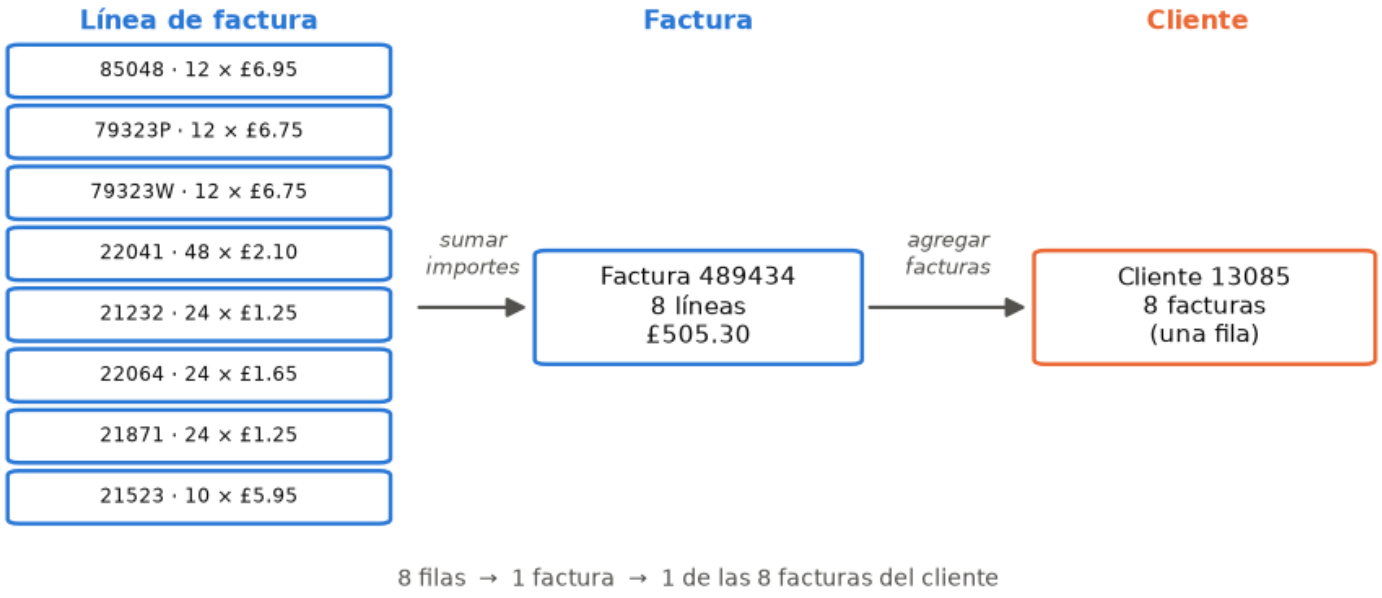
¿Cuál es el importe de esta factura? ¿Qué saldría si sumáramos la columna de precios?

**Una factura de tres líneas**

10 unidades a 2 £ · 5 unidades a 4 £ · 1 unidad a 30 £

Vuestras respuestas

# Para llegar al cliente hay que agregar




## Línea → factura → cliente

- La factura 489434 tiene 8 líneas, pero es una sola compra
- El importe es cantidad × precio, línea a línea
- La frecuencia se mide en facturas distintas, no en líneas

Figura 01.1 del capítulo: granularidad con datos reales

# Lo que dice y lo que hace el cliente

| | Estático | Dinámico |
|---|---|---|
| **Explícito (declarado)** | **País de facturación**<br>El único dato declarado de Online Retail II | **Preferencias marcadas, valoraciones**<br>Lo que dice hoy; puede cambiar |
| **Implícito (observado)** | **Fecha de la primera compra**<br>Antigüedad observada | **Días desde la última compra, gasto acumulado**<br>Solo tiene sentido a una fecha |

# No todas las compras tienen dueño

**Identificados**

Un identificador estable: número de cliente, login, email

**Anónimos**

Sabemos que hay alguien (una cookie, una sesión), pero no quién

**Sin identificador**

No hay forma de atribuir el evento a nadie

**22,8 %**

de todas las líneas del dataset no tiene customer_id

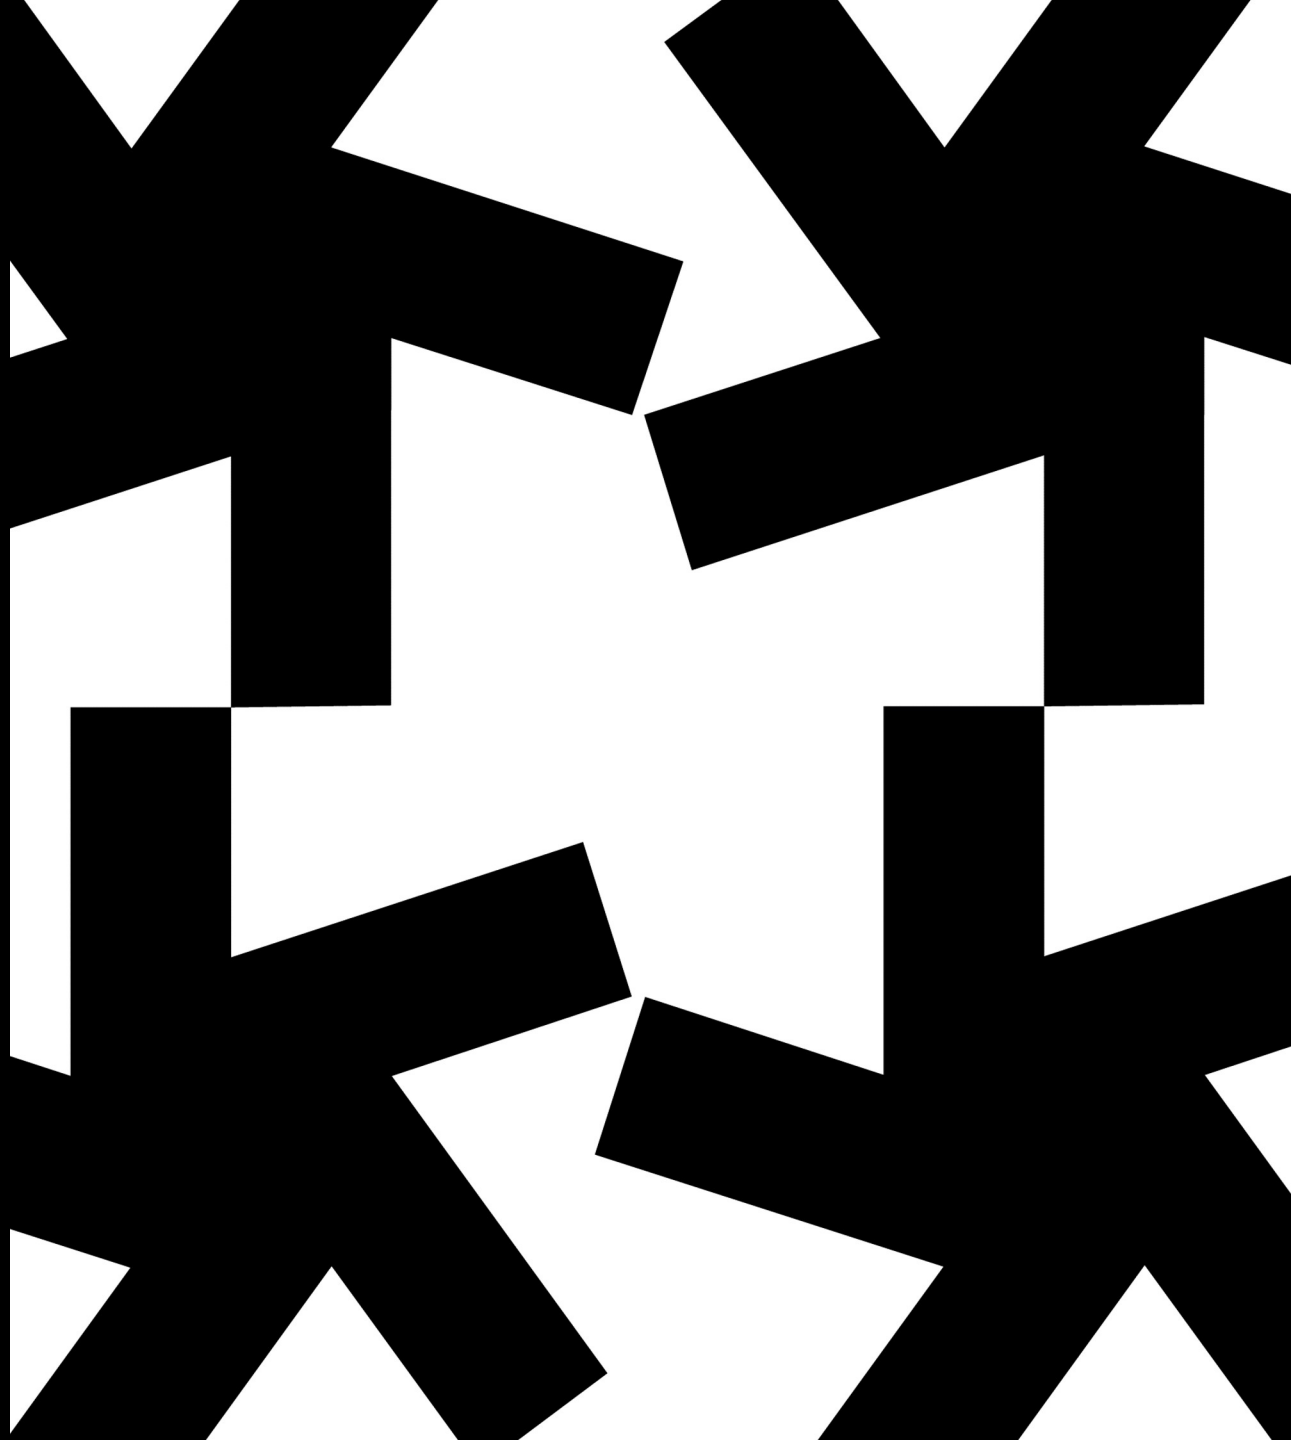
**No se descartan sin medir cuánto representan.**

# Calidad del dato antes de modelar

Bloque D

unie*
Universidad

Planeta Formación y Universidades



# Cada hallazgo de la auditoría es una decisión

**34 335**

líneas duplicadas exactas (3,2 % de todas las líneas)

**19 494**

líneas de cancelación, facturas «C…» (1,8 % de todas)

**62**

códigos que no empiezan por dígito: portes y comisiones, pero también productos reales

**Eliminar**

y documentarlo

**Guardar aparte**

como devoluciones

**Excluir 17 con una lista**

escrita, código a código

# ¿Qué cifra comunicaríais a marketing?

**VOTAD**

Antes de limpiar, una parte de las ventas no tiene cliente.
¿Qué cifra comunicaríais a marketing?

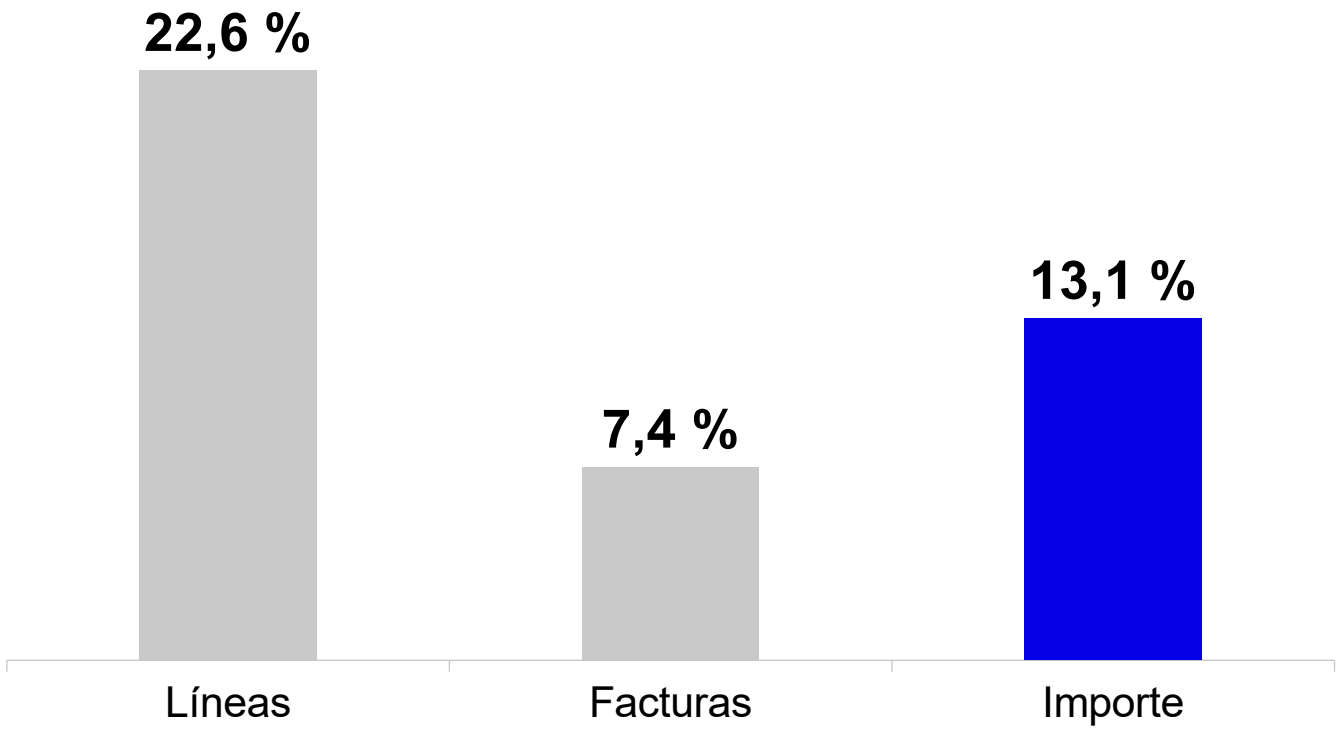
**A** 22,7 % de las líneas de venta

**B** 7,8 % de las facturas de venta

**C** 15,4 % del importe de venta

Vuestras respuestas

# Tras limpiar, la tabla cubre el 86,9 % del importe




Ventas sin cliente, tras quitar duplicados y códigos que no son producto

**86,9 %**

del importe de ventas lo explica la tabla de cliente

**La cifra que se comunica es la del importe.**

# Un error de datos es un error de negocio

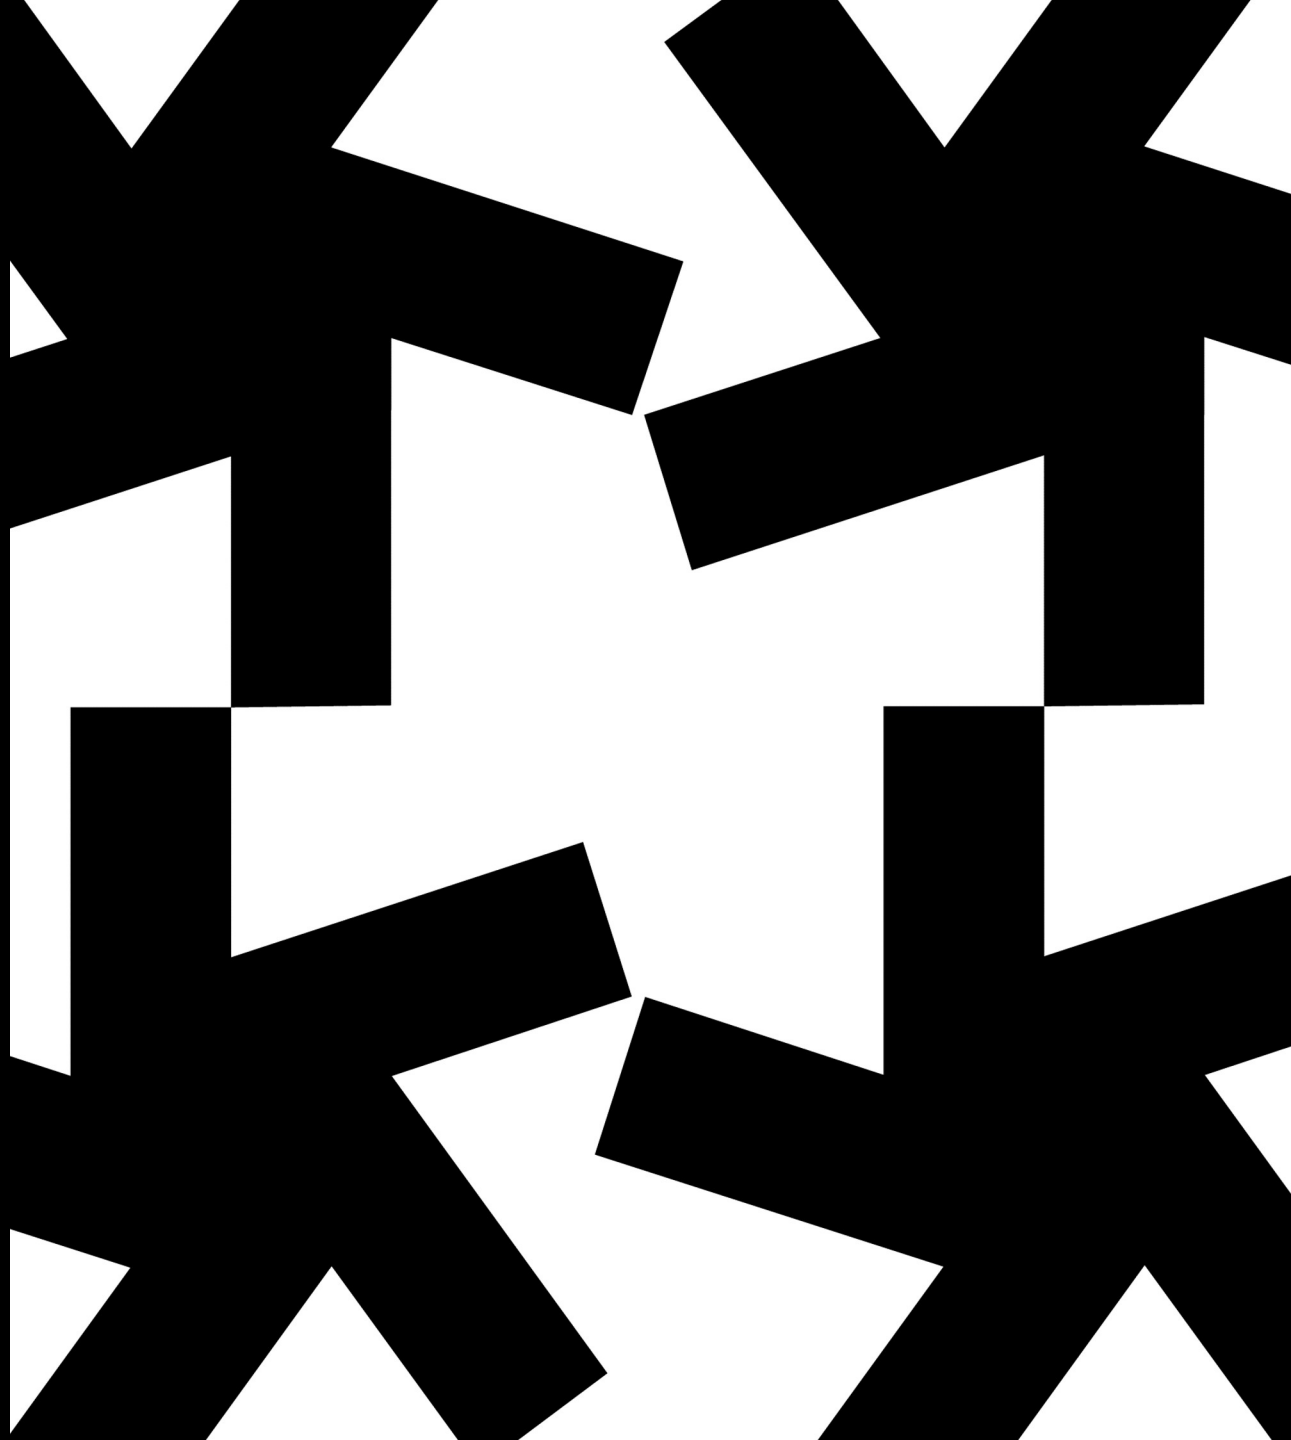
| | |
|---|---|
| **Duplicados sin eliminar** | Clientes en el programa VIP que no lo merecen |
| **Cancelaciones sumadas como ventas** | Quien compra y devuelve todo parece un gran cliente |
| **Portes contados como producto** | «POSTAGE» recomendado a todo el mundo |
| **Líneas sin cliente descartadas en silencio** | El informe olvida el 13 % de la facturación |

# Construir el perfil de cliente

Bloque E

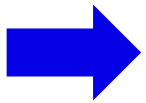
unie*
Universidad

Planeta Formación y Universidades



# RFM se puede calcular a mano

| Factura | Cliente | Fecha | Importe |
|---|---|---|---|
| F1 | Ana | 2011-11-02 | 60 |
| F2 | Ana | 2011-11-28 | 40 |
| F3 | Bruno | 2011-10-15 | 250 |
| C4 | Ana | 2011-11-30 | −20 |
| F5 | (sin cliente) | 2011-12-05 | 35 |
| F6 | Carla | 2011-06-01 | 30 |



| Cliente | R (días) | F | M |
|---|---|---|---|
| **Ana** | 12 | 2 | 100 |
| **Bruno** | 56 | 1 | 250 |
| **Carla** | 192 | 1 | 30 |

A fecha 2011-12-10, sin la cancelación ni la factura sin cliente

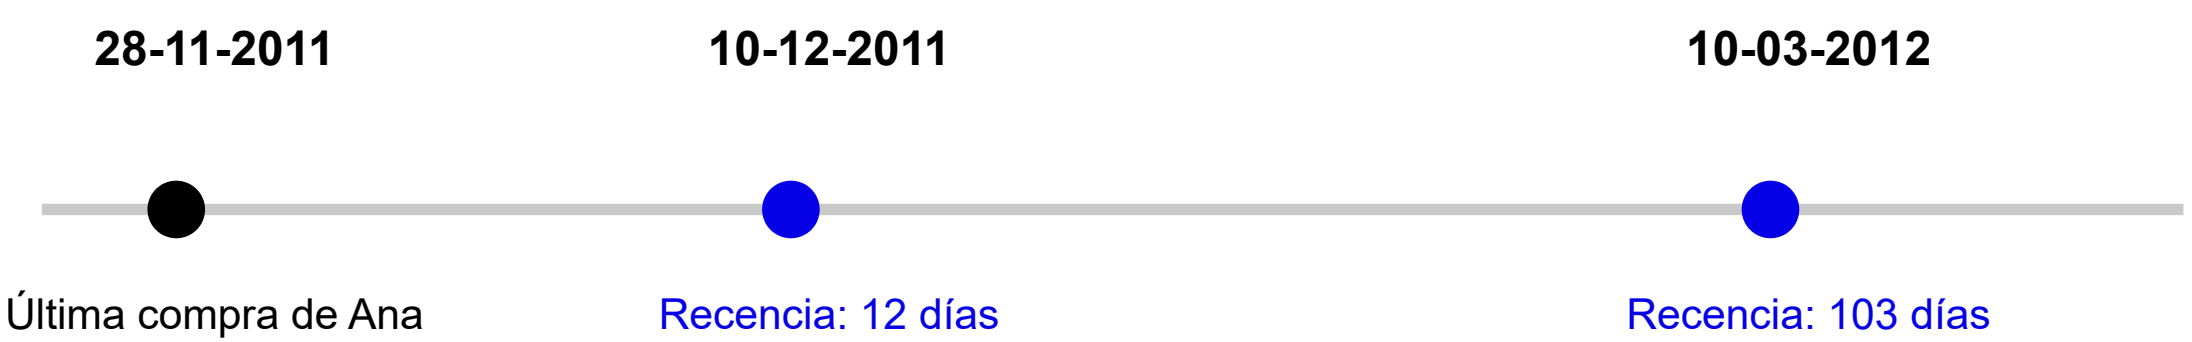
# ¿Qué recencia tiene este cliente?

**POR PAREJAS**

Un cliente compró por última vez el 1 de noviembre de 2011. ¿Cuál es su recencia a 2011-12-10? ¿Y a 2011-11-15? ¿Qué implica que sean distintas?

Vuestras respuestas

# Toda variable es «a fecha de»




**Nunca «hoy»**

El resultado cambiaría en cada ejecución

**Solo datos anteriores a la fecha**

Usar datos posteriores es hacer trampa (clase 6)

# ¿Es el 12346 uno de nuestros mejores clientes?

**VOTAD**

El cliente 12346 ha comprado 77 352,96 £ en 3 facturas. ¿Es uno de nuestros mejores clientes?

**A** Sí

**B** No

**C** Depende

Vuestras respuestas

# Gasto y devoluciones se guardan por separado

## Cliente 12346

**77 352,96 £**

compró (monetary, gasto bruto)

**77 183,60 £**

factura cancelada entera 16 minutos después (return_amount)

### return_share = 1,00

Lo devuelto entre lo comprado: prácticamente todo

### Por separado, no solo el neto

Con el neto no veríamos que compra mucho y lo devuelve; con el bruto lo trataríamos como VIP

# Once variables, todas a 2011-12-10

**Compra**

- recency_days
- frequency
- monetary
- avg_ticket
- n_products
- tenure_days

**Devoluciones**

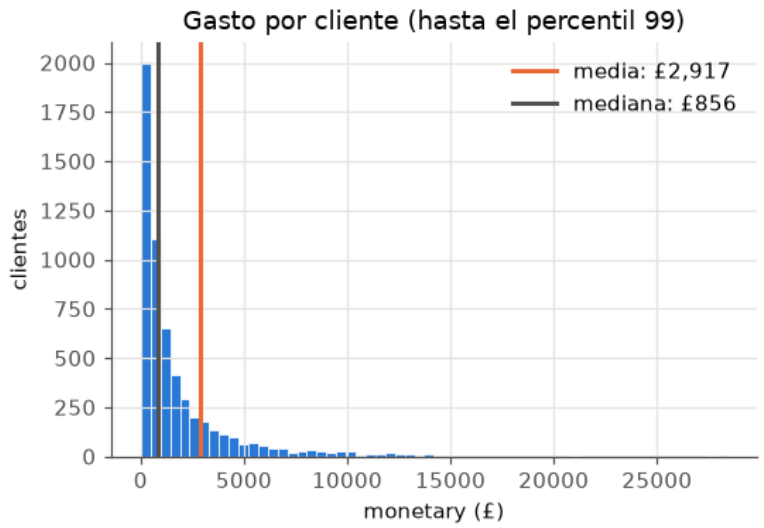
- n_return_invoices
- return_amount
- has_returns
- return_share

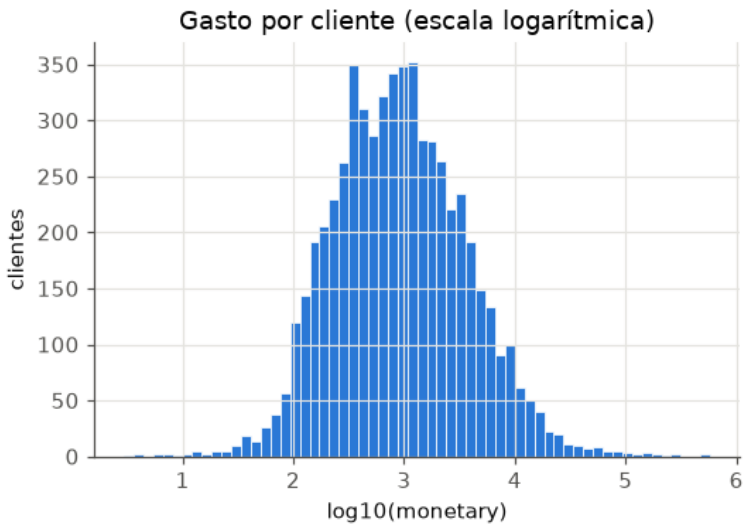
**Mercado**

- country

tenure_days solo ve desde diciembre de 2009: la antigüedad real puede ser mayor.

# El cliente medio no existe




**2 917 £ / 856 £**

media frente a mediana del gasto de todos los clientes

**25,3**

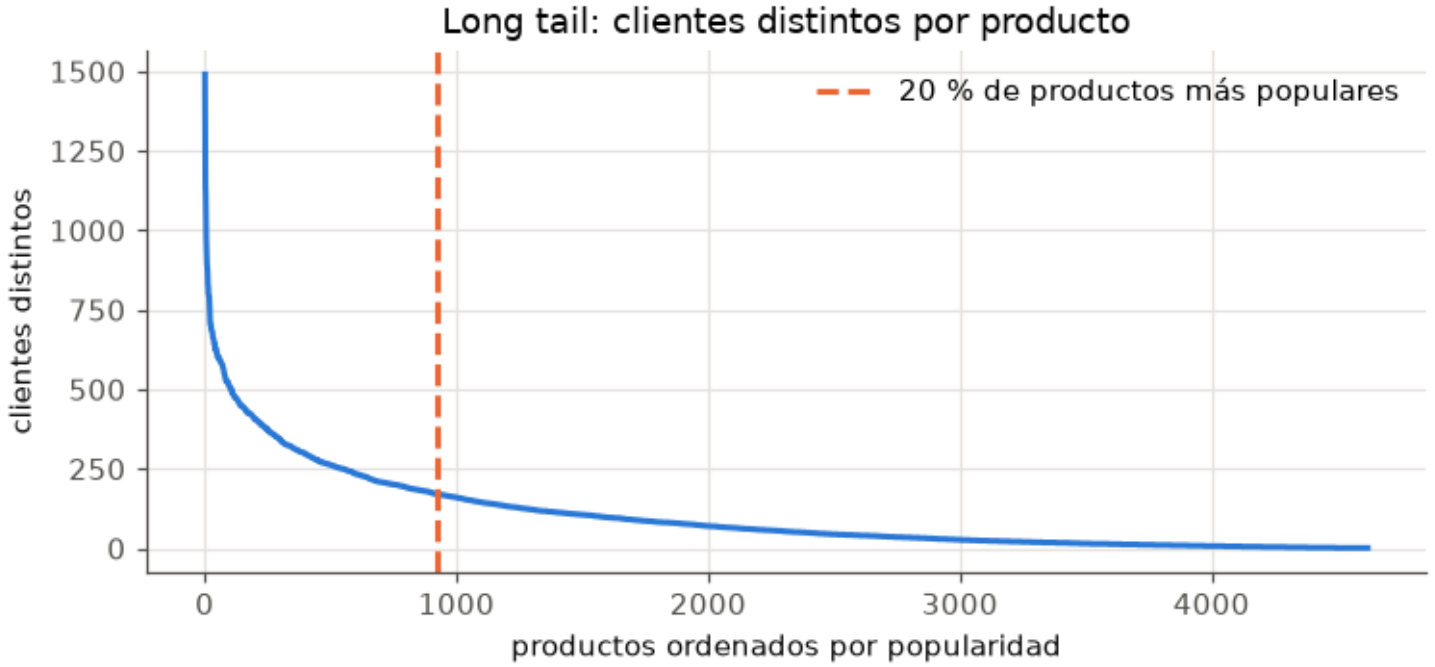
asimetría del gasto (una distribución simétrica tiene 0)

**31,9 %**

del gasto lo concentra el 1 % de los clientes

Figura 01.2 del capítulo: gasto por cliente (hasta el percentil 99 y en escala logarítmica)

# Pocos productos reúnen la mayoría de las relaciones




**61,8 %**

de los pares cliente-producto distintos los reúne el 20 % de los productos

### Baseline de popularidad

Lo más popular que el cliente aún no ha comprado: el listón de los recomendadores (clases 9–12)

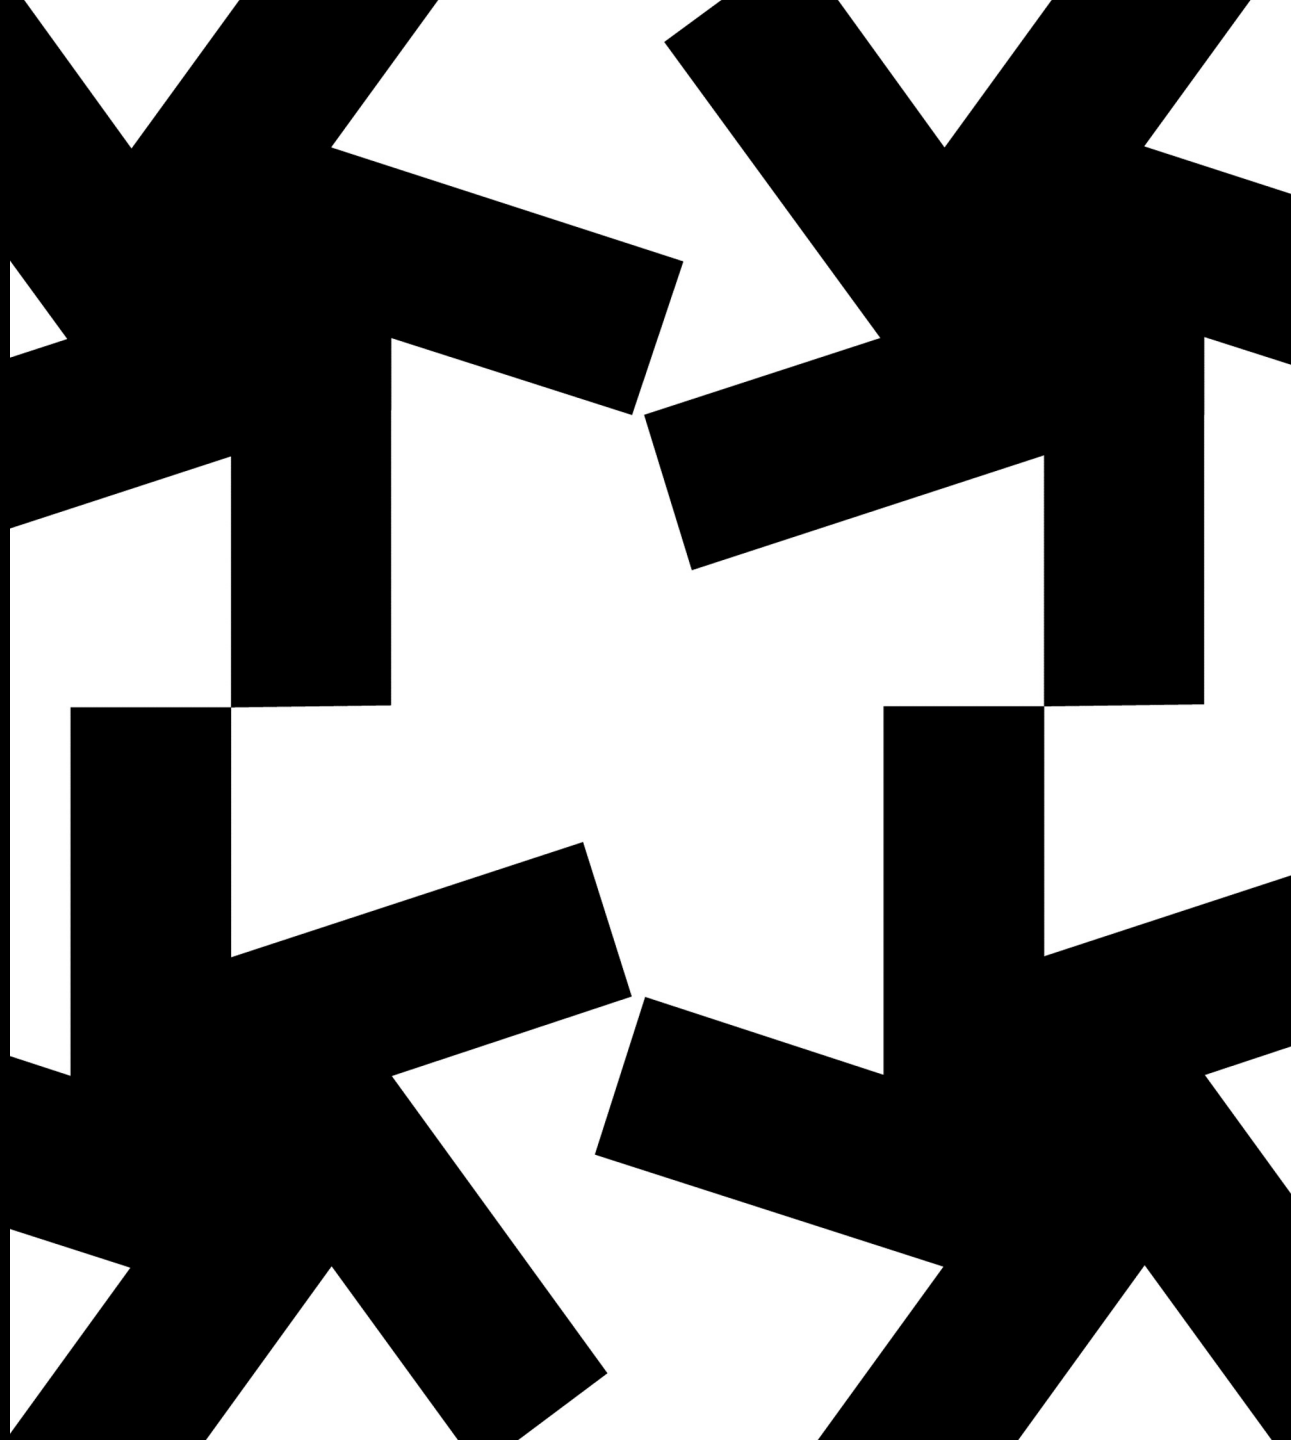
Figura 01.4 del capítulo: clientes distintos por producto

# Uso responsable

Bloque F

unie*
Universidad

Planeta Formación y Universidades



# Cada variable necesita un uso previsto

| Necesaria | Dudosa | Inferencia excesiva |
| --- | --- | --- |
| • Recencia: decide a quién reactivar<br>• Devoluciones: evitan falsos VIP | • Hora habitual de compra: ¿qué decisión depende de ella? | • «Tiene problemas económicos» porque su gasto ha caído |

**Diccionario de variables**

Definición, cálculo, uso previsto y sensibilidad de cada variable: el contrato entre datos y marketing

# Tratar datos de clientes necesita una base legal

**1**

### Base legal

Todo tratamiento necesita una: contrato, consentimiento, interés legítimo… (art. 6)

**2**

### Minimización y finalidad

Datos para fines determinados, sin usos incompatibles después (art. 5)

**3**

### Perfilar es tratar

Las decisiones solo automatizadas con efectos significativos están protegidas (art. 22)

**Seudonimizado no es anonimizado:** customer_id se puede volver a enlazar con la persona.

# ¿Hasta dónde podemos inferir sobre un cliente?

**DEBATE**

## ¿Qué inferencias son razonables para personalizar y cuáles cruzan la línea? ¿Cambia si es para uso interno o se le muestra al cliente?

**Todo lo que se deduce de las compras se puede usar**

¿Particular o empresa? ¿Compra para un bebé?

**Solo lo que el cliente aceptaría ver**

¿Particular o empresa? ¿Compra para un bebé?

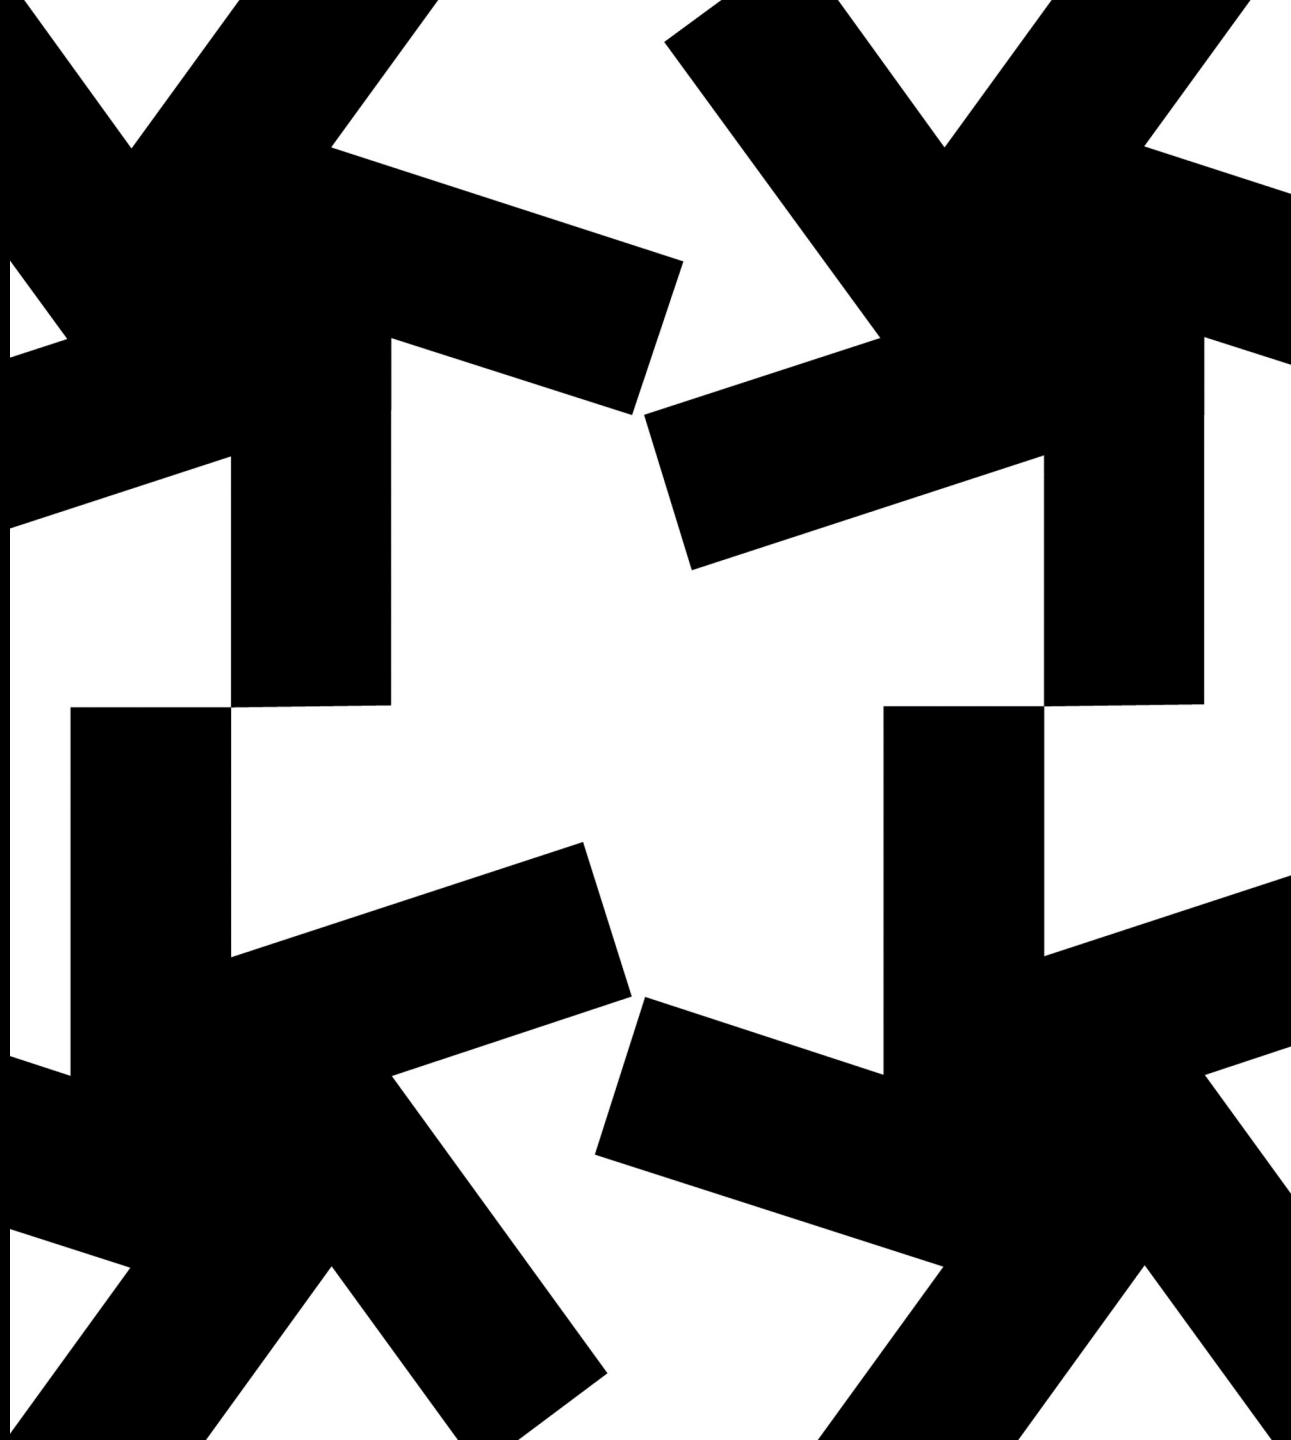
Vuestras respuestas

# AI notebook

## Bloque G

unie*
Universidad

Planeta Formación y Universidades



# Antes de empezar

## Necesitas

- Python 3 con Jupyter
- pandas, numpy y matplotlib
- pyarrow, para leer los .parquet

## Copia junto al notebook, sin cambiarles el nombre

| Fichero | Tamaño | Para qué sirve |
|---|---|---|
| online_retail_ii.parquet | 7 MB | Las ventas en bruto |
| lineas_limpias.parquet | 6 MB | La demo y el rescate |
| customers_referencia.parquet | 0,2 MB | Comprobar tu tabla |

# Demo: la misma tabla con SQL y con pandas

**SQL (SQLite)**

```
SELECT customer_id,
  COUNT(DISTINCT invoice) AS frequency,
  SUM(quantity * price)  AS monetary,
  julianday('2011-12-10')
    - julianday(MAX(date(invoice_date)))
                         AS recency_days
FROM sales
GROUP BY customer_id
```

**pandas**

```
muestra.groupby("customer_id").agg(
    frequency=("invoice", "nunique"),
    monetary=("amount", "sum"),
    last_purchase=("invoice_date", "max"),
)

# recency_days = FECHA_REFERENCIA
#   - last_purchase (en días)
```

# Laboratorio: de las facturas a la tabla de cliente

| | | |
|---|---|---|
| **B1** | Granularidad | Ej. 1 |
| **B2** | Auditoría | Ej. 2, 3 |
| **B3** | Limpieza y cobertura | Ej. 4 |
| **B4** | SQL y pandas a escala | Ej. 5 |
| **B5** | Perfil de cliente | Ej. 6, 7 |
| **B6** | Distribuciones y long tail | Ej. 8, 9 |
| **B7** | Diccionario de variables | Ej. 10 |

## Entregables

salidas/customers.parquet

salidas/diccionario_variables.csv

salidas/diccionario_metadatos.csv

## Si te atascas

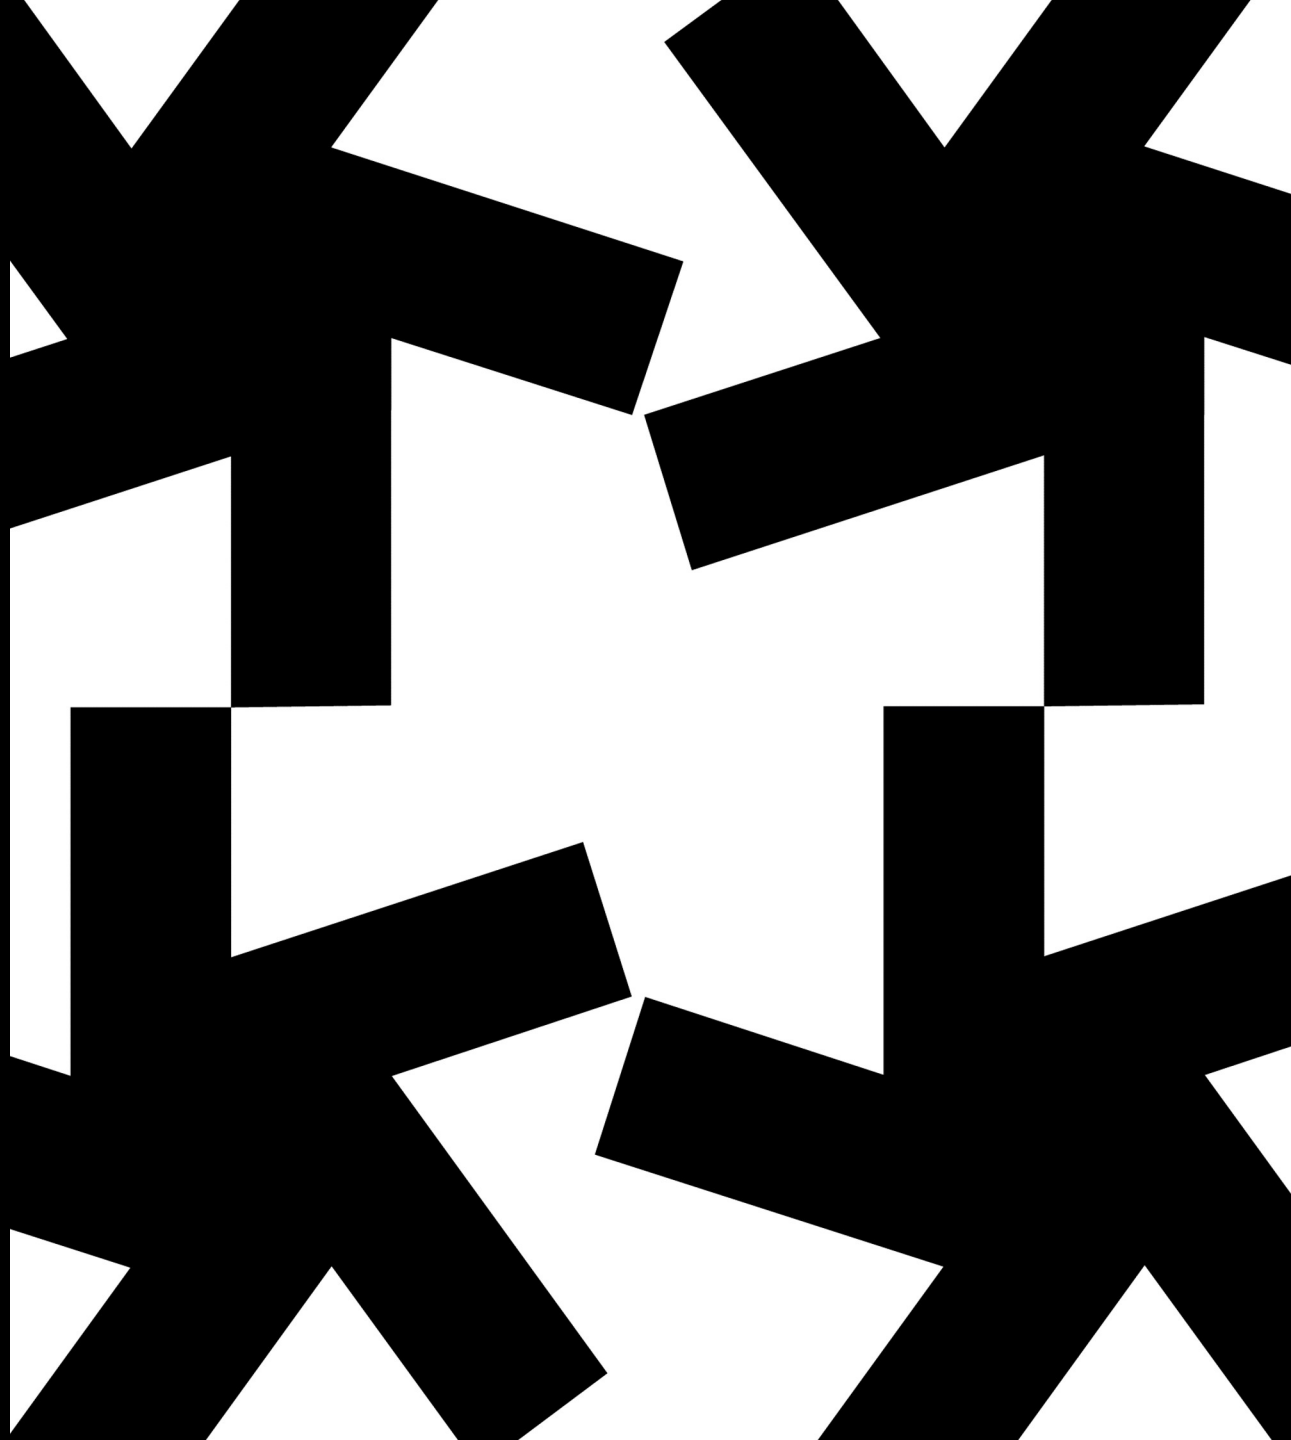
La celda de rescate de la parte siguiente: cambia USAR_RESCATE = False por True

# Síntesis

## Bloque H

unie*
Universidad

Planeta Formación y Universidades



# Vuestro turno: de la métrica a la decisión

### 1. La cadena con tus palabras

Interpretación, decisión, limitación y guardrail

Añade un caso tuyo del laboratorio, con su cifra

### 2. Las tres preguntas

¿Cuántos clientes tenemos?

¿Cuáles son los mejores?

¿A quién escribimos?

### 3. Errores frecuentes

Marca en la lista de 01.9 los que has cometido o esquivado, y en qué ejercicio

En la parte C del notebook. Después lo corregimos en común.

# De la métrica a la decisión

| Paso | En esta clase |
|---|---|
| **Métrica técnica** | Cobertura del 86,9 % del importe; 3,2 % de duplicados; asimetría del gasto 25,3 |
| **Interpretación** | La tabla describe a la mayoría del negocio, no a todo; el cliente medio no existe |
| **Decisión** | Clientes identificados, a 2011-12-10, devoluciones aparte, medianas y percentiles |
| **Limitación** | El 13,1 % del importe queda fuera; el gasto bruto sobrevalora a quien devuelve mucho; solo vemos desde diciembre de 2009 |
| **Guardrail** | Todo informe indica fecha y cobertura; se revisa a quien devuelve mucho antes de un VIP |

# Volviendo a la reunión

## ¿Cuántos clientes tenemos?

5 852 con al menos una compra (5 942 identificadores), que explican el 86,9 % del importe

## ¿Cuáles son los mejores?

Depende de la definición: por gasto bruto saldría quien lo devuelve todo; mirad return_share

## ¿A quién escribimos?

La recencia da candidatos; decidir exige riesgo y valor (clases 6 y 7) y el coste de la acción (14)

# Para discutir y lo que viene

**Para discutir: elegimos una**

- Si quienes compran sin identificarse fueran distintos, ¿qué sesgo tendría la tabla?
- ¿Qué inferencias son razonables para personalizar y cuáles cruzan la línea?
- ¿Quién decide cómo se usa la etiqueta de quien devuelve mucho?
- ¿Quién debería poder enlazar customer_id con la persona?

## Clase 2

¿Qué tipos de clientes tenemos y cuáles no encajan?

La tabla de hoy es su entrada: segmentos y atípicos