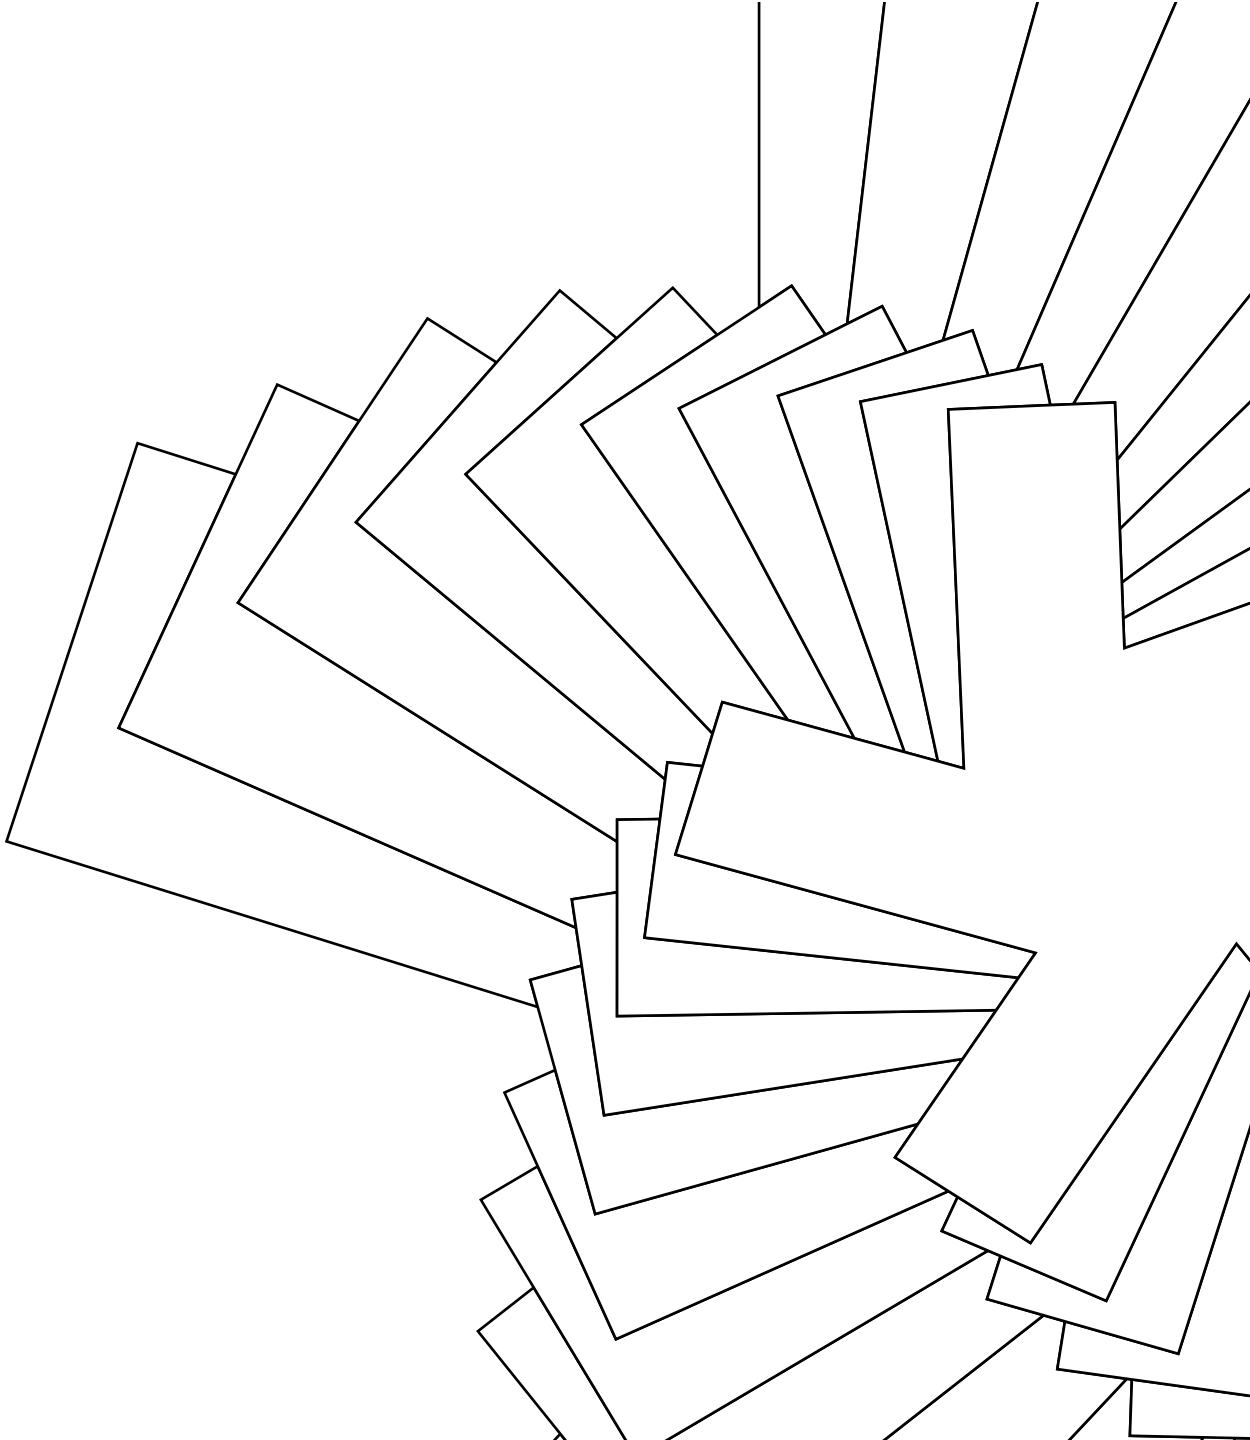
Clustering

Clase 2 · Segmentos y atípicos de los clientes

Asignatura: Inteligencia Artificial para la personalización y experiencia de cliente

Docente: Álvaro de la Riva



unie*
Universidad

Planeta Formación y Universidades

5 852 clientes no caben en 5 852 campañas

«No puedo diseñar una campaña por cliente. Necesito unos pocos grupos que pueda explicar a mi equipo y tratar de forma distinta. Y quiero saber qué clientes no encajan en ninguno.»

1. Segmentar

Grupos homogéneos por dentro y distintos entre sí

2. Detectar atípicos

Los clientes que no se parecen a ningún otro

¿Qué tipos de clientes creéis que tenemos?

¿QUÉ ESPERÁIS?

Describid dos o tres grupos de clientes que creéis que tenemos, y un tipo de cliente que no encajaría en ninguno

Vuestras respuestas

Hoy convertimos clientes en segmentos



Lo que te llevas

customers_segments.parquet

La tabla de cliente con segmento y marca de atípico

Fichas de segmento

Nombre, tamaño, valor, comportamiento y acción

Catálogo de atípicos

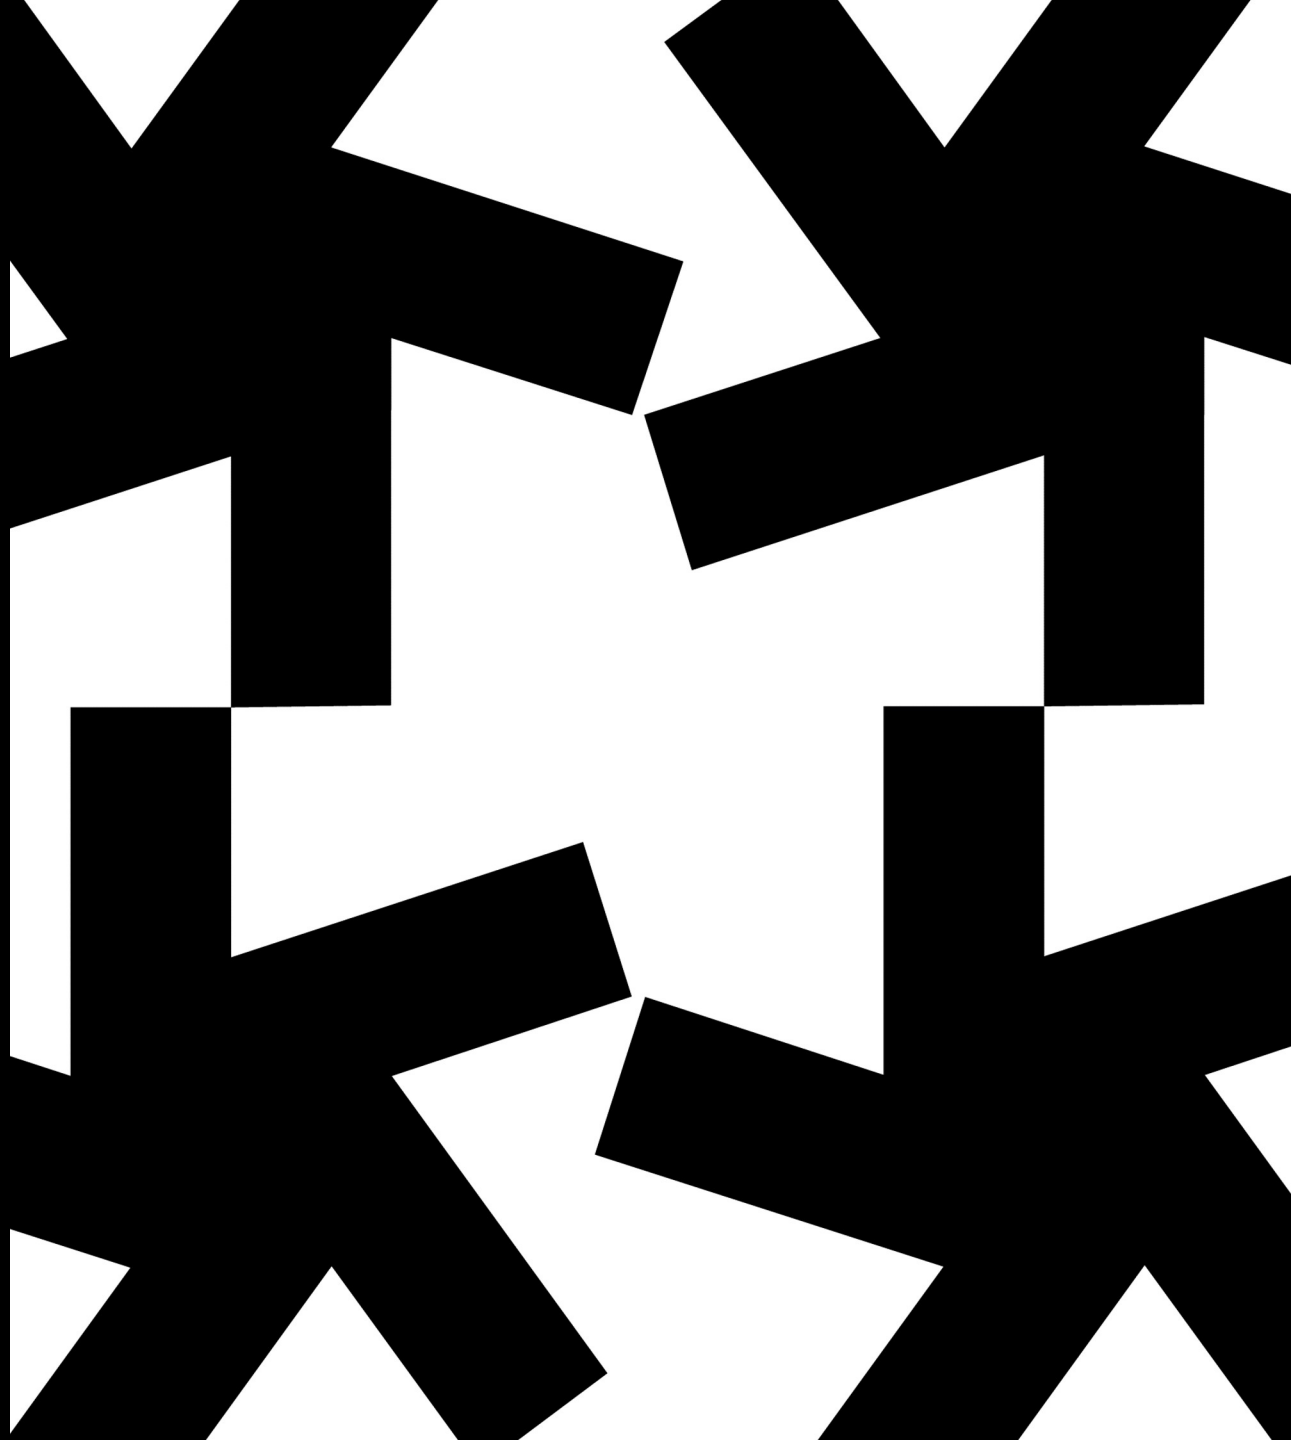
Quién no encaja, por qué y qué hacer con él

Aprender sin etiquetas y medir el parecido

Bloque B

unie*
Universidad

Planeta Formación y Universidades



Sin etiquetas, los grupos se juzgan por su utilidad

Con etiqueta (supervisado)

Hay una respuesta conocida con la que comparar

¿Reseña positiva? (clase 4)

¿Abandonó? (clase 6)

¿Cuánto gastará? (clase 7)

Sin etiqueta (no supervisado)

No hay respuesta correcta: se juzga si los grupos son

compactos

estables

útiles para decidir

Otras variables u otro algoritmo darían otros grupos, igual de «correctos».

Cada cliente es un punto; parecerse es estar cerca

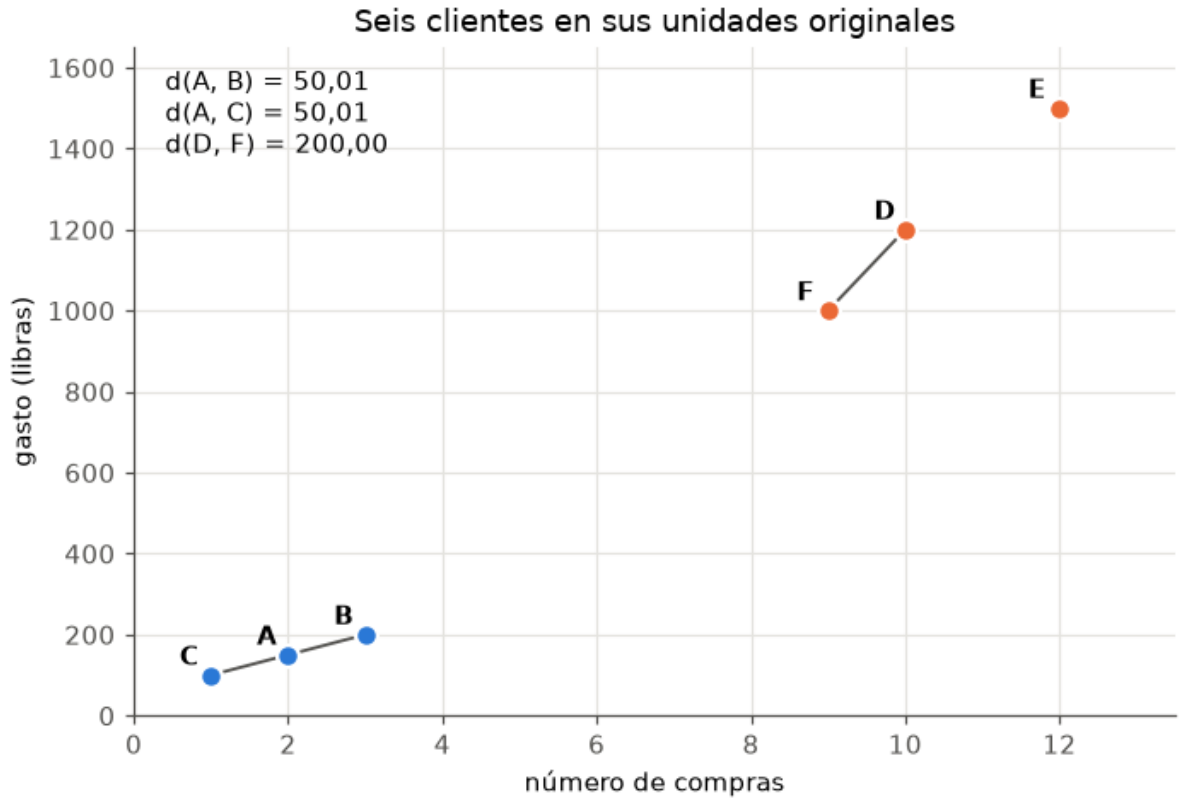


Figura 02.1 del capítulo: seis clientes en compras y libras, con tres distancias.

Distancia euclídea

La línea recta entre dos clientes

Cuanto más cerca, más parecidos

Una dimensión por variable

¿Qué variable manda en esta distancia?

PREGUNTA AL AULA

Sin escalar, ¿qué variable domina su distancia? ¿Y si el gasto estuviera en miles de libras?

Dos clientes

Se diferencian en 2 compras y en 300 libras de gasto

Vuestras respuestas

Tras escalar, A vuelve a parecerse a B

$$z = (x - \text{media}) / \text{desviación típica}$$

Todas las variables: media 0 y desviación típica 1

Distancias con las variables escaladas

0,24

de A a B (casi iguales en todo)

2,24

de A a G (6 veces más compras)

Cliente G: 12 compras y 160 £

Compra seis veces más que A y gasta casi lo mismo. B se parece a A en todo.

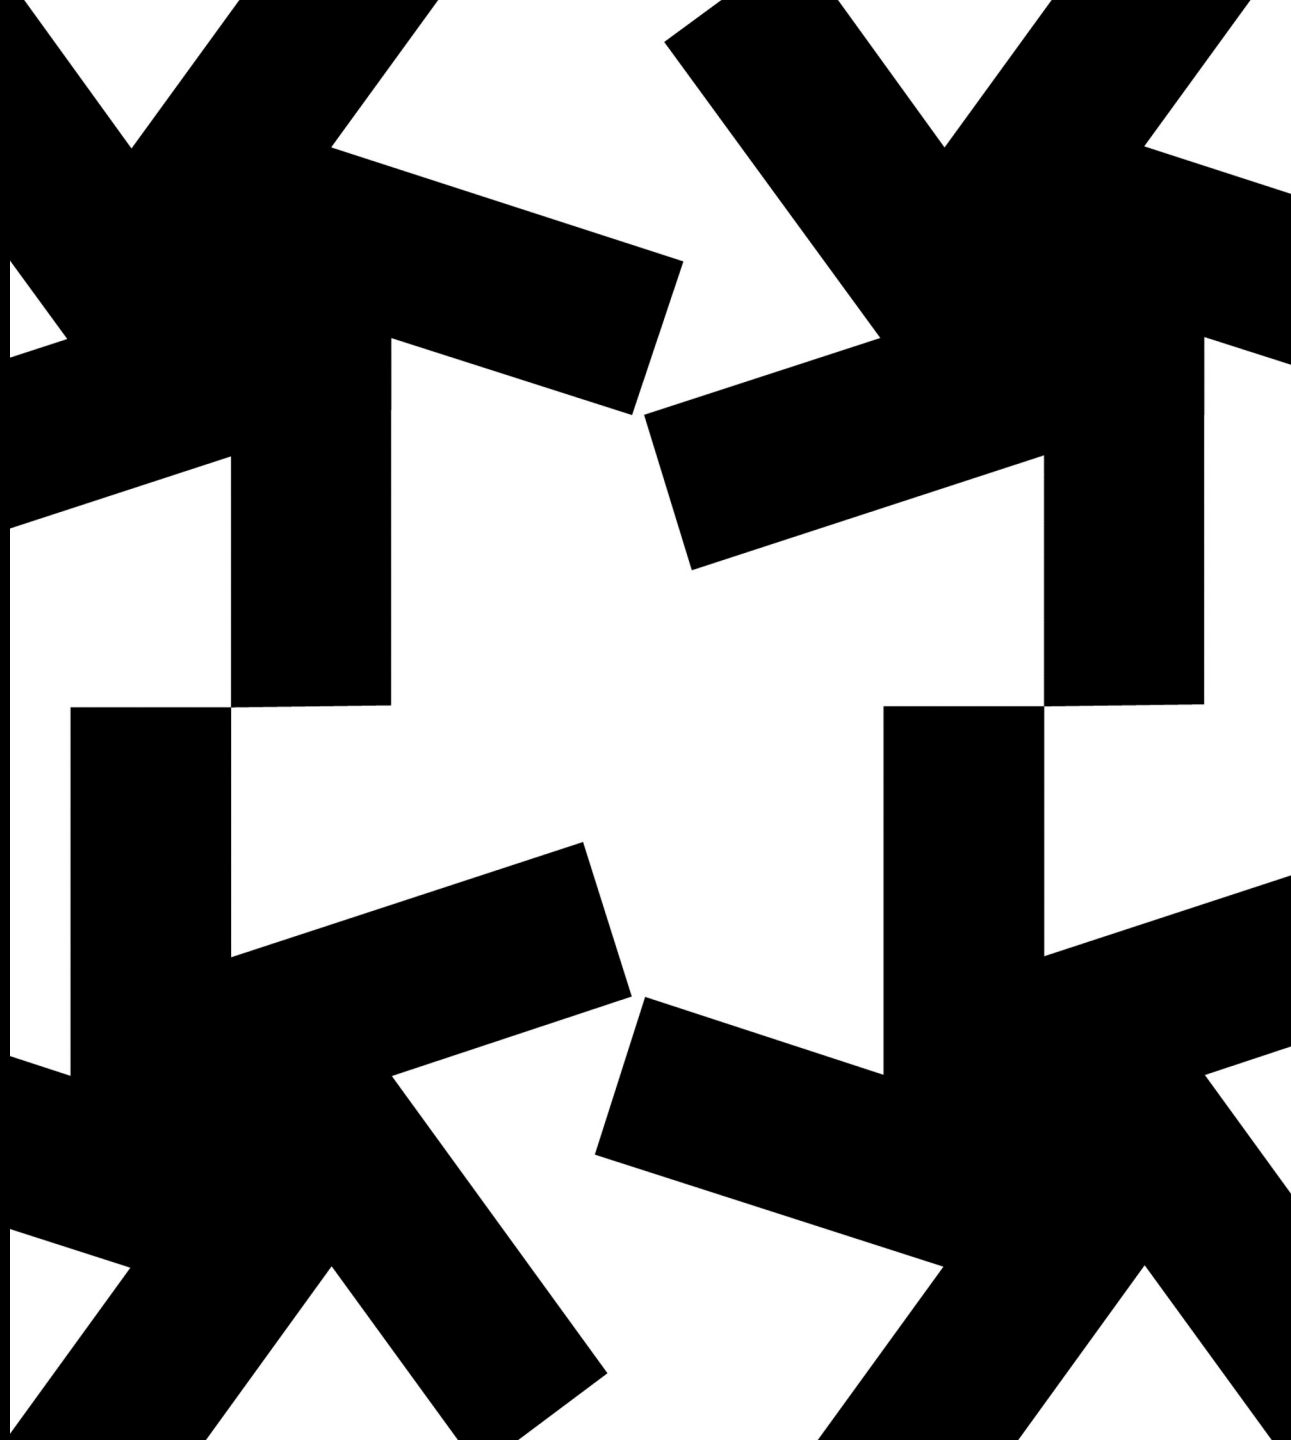
Escalar quita a las unidades el poder de decidir quién se parece a quién.

K-means: cuántos grupos

Bloque C

unie*
Universidad

Planeta Formación y Universidades



K-means: asignar, recalcular, repetir

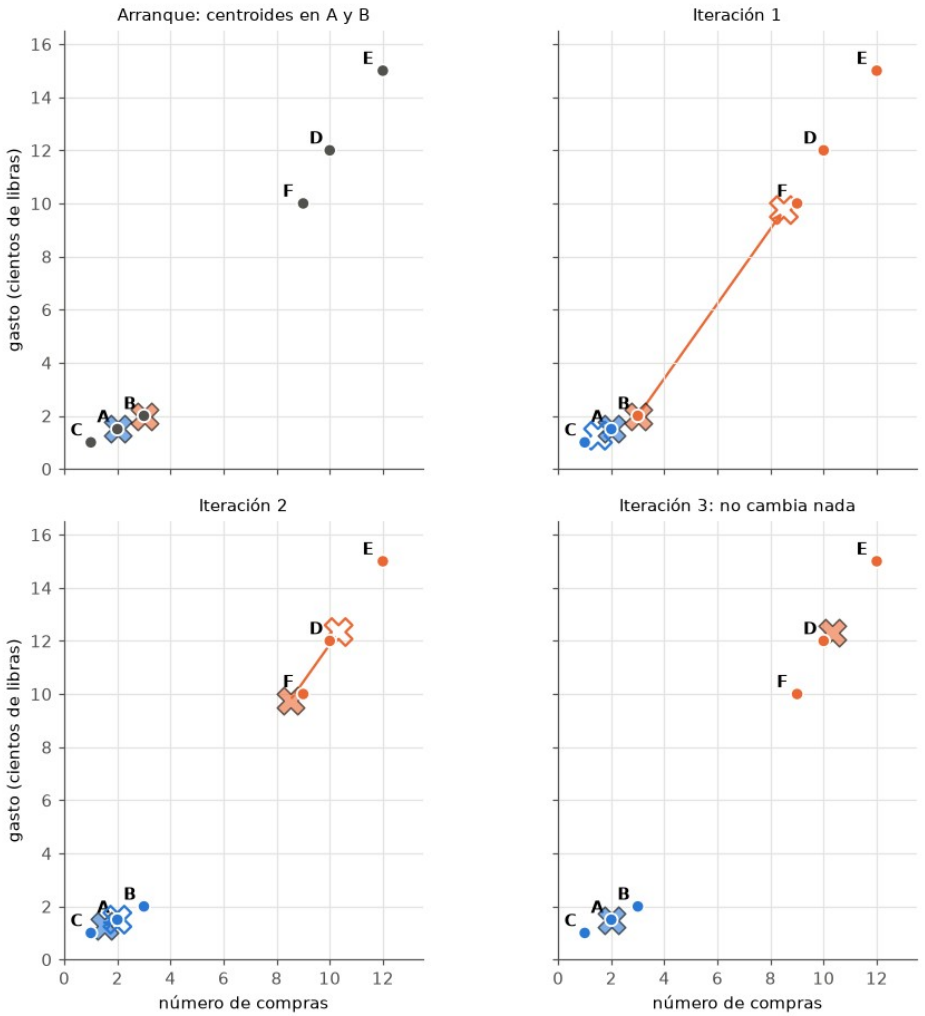


Figura 02.4 del capítulo: K-means con K = 2 desde un arranque malo.

Cuatro pasos

1. Elegir K centroides iniciales
2. Asignar cada cliente al más cercano
3. Recalcular cada centroide como la media
4. Repetir hasta que nada cambie

Objetivo: grupos compactos (inercia mínima)

Silhouette y ARI miden si son compactos y estables

Silhouette: ¿grupos compactos y separados?

¿Cada cliente está más cerca de su grupo que del grupo vecino?

De −1 a 1: cerca de 1, bien dentro; cerca de 0, en la frontera

ARI (Adjusted Rand Index): ¿grupos estables?

¿Salen los mismos grupos con otra semilla?

1 = exactamente los mismos; 0 = lo que daría el azar

El codo: la inercia siempre baja al añadir grupos; se busca dónde deja de bajar mucho.

¿Cuántos grupos elegiríais?

VOTAD

Con estas cifras, ¿cuántos grupos elegiríais?

A K = 2

B K = 3

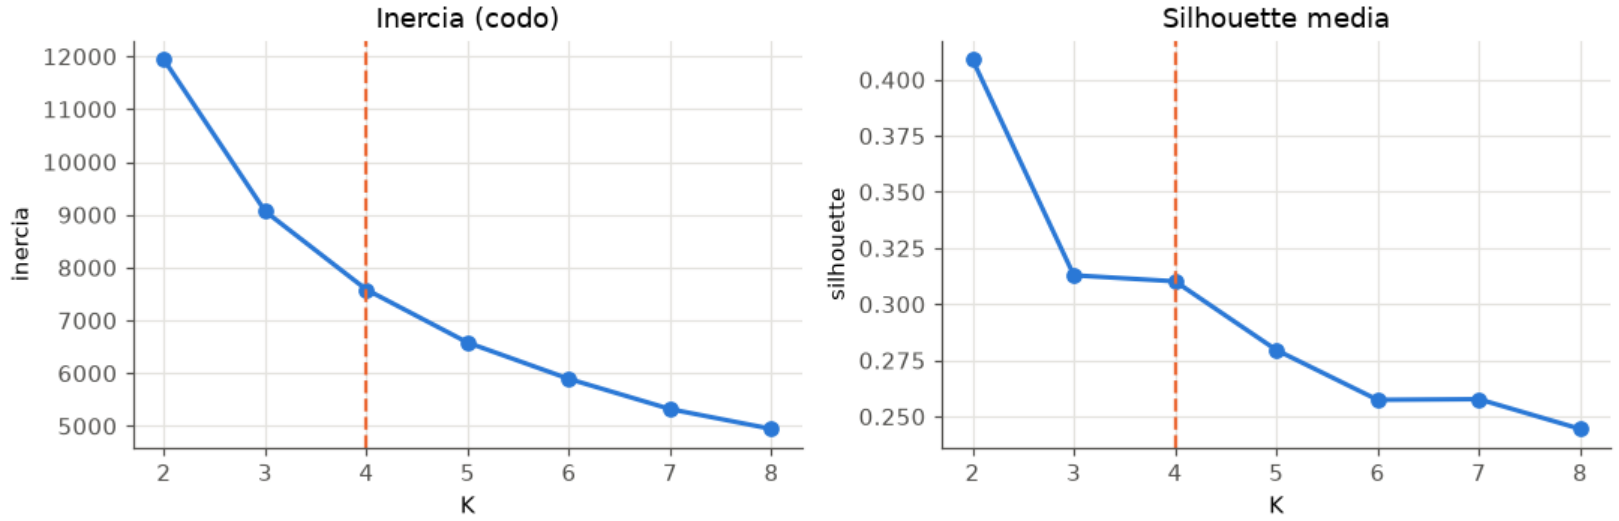
C K = 4

D K = 5

K	2	3	4	5
Silhouette media	0,41	0,31	0,31	0,28
Estabilidad entre semillas (ARI)	1,00	0,99	0,99	0,94

K-means sobre los 5 852 clientes (cuatro variables, logaritmo y escalado).

Las métricas acotan K; el negocio decide



K = 4

la decisión

Figura 02.5 del capítulo: inercia y silhouette para K = 2…8; la línea marca K = 4.

- Tan compacto (0,31) y estable (0,99) como K = 3, con un grupo más; el menor, de 1 235 clientes
- K = 2 tiene la mejor silhouette (0,41), pero no permite campañas distintas
- Nota: la inercia mide la suma de las distancias al cuadrado de cada punto a su centroide asignado. Mide cómo de compactos son los clústeres por dentro

El 21,7 % de los clientes suma el 73,9 % del gasto bruto

Cluster	Clientes	% clientes	% gasto bruto	Recencia (días)	Facturas	Gasto (£)
0	1 235	21,1	8,2	24	3	807
1	1 511	25,8	14,7	241	4	1 176
2	1 267	21,7	73,9	20	12	4 623
3	1 839	31,4	3,2	393	1	237

Recencia, facturas y gasto: medianas de cada cluster. Porcentajes sobre los 5 852 clientes y su gasto bruto total.

¿Qué hará K-means con un mayorista?

¿QUÉ ESPERÁIS?

Añadimos un mayorista W y pedimos dos grupos. ¿Cómo quedarán?

Cliente	A	B	C	D	E	F	W
Compras	2	3	1	10	12	9	11
Gasto (cientos de £)	1,5	2	1	12	15	10	90

Vuestras respuestas

Un solo mayorista basta para romper los grupos

Grupo 1

A, B, C, D, E y F: pequeños y grandes juntos

Grupo 2

W, solo

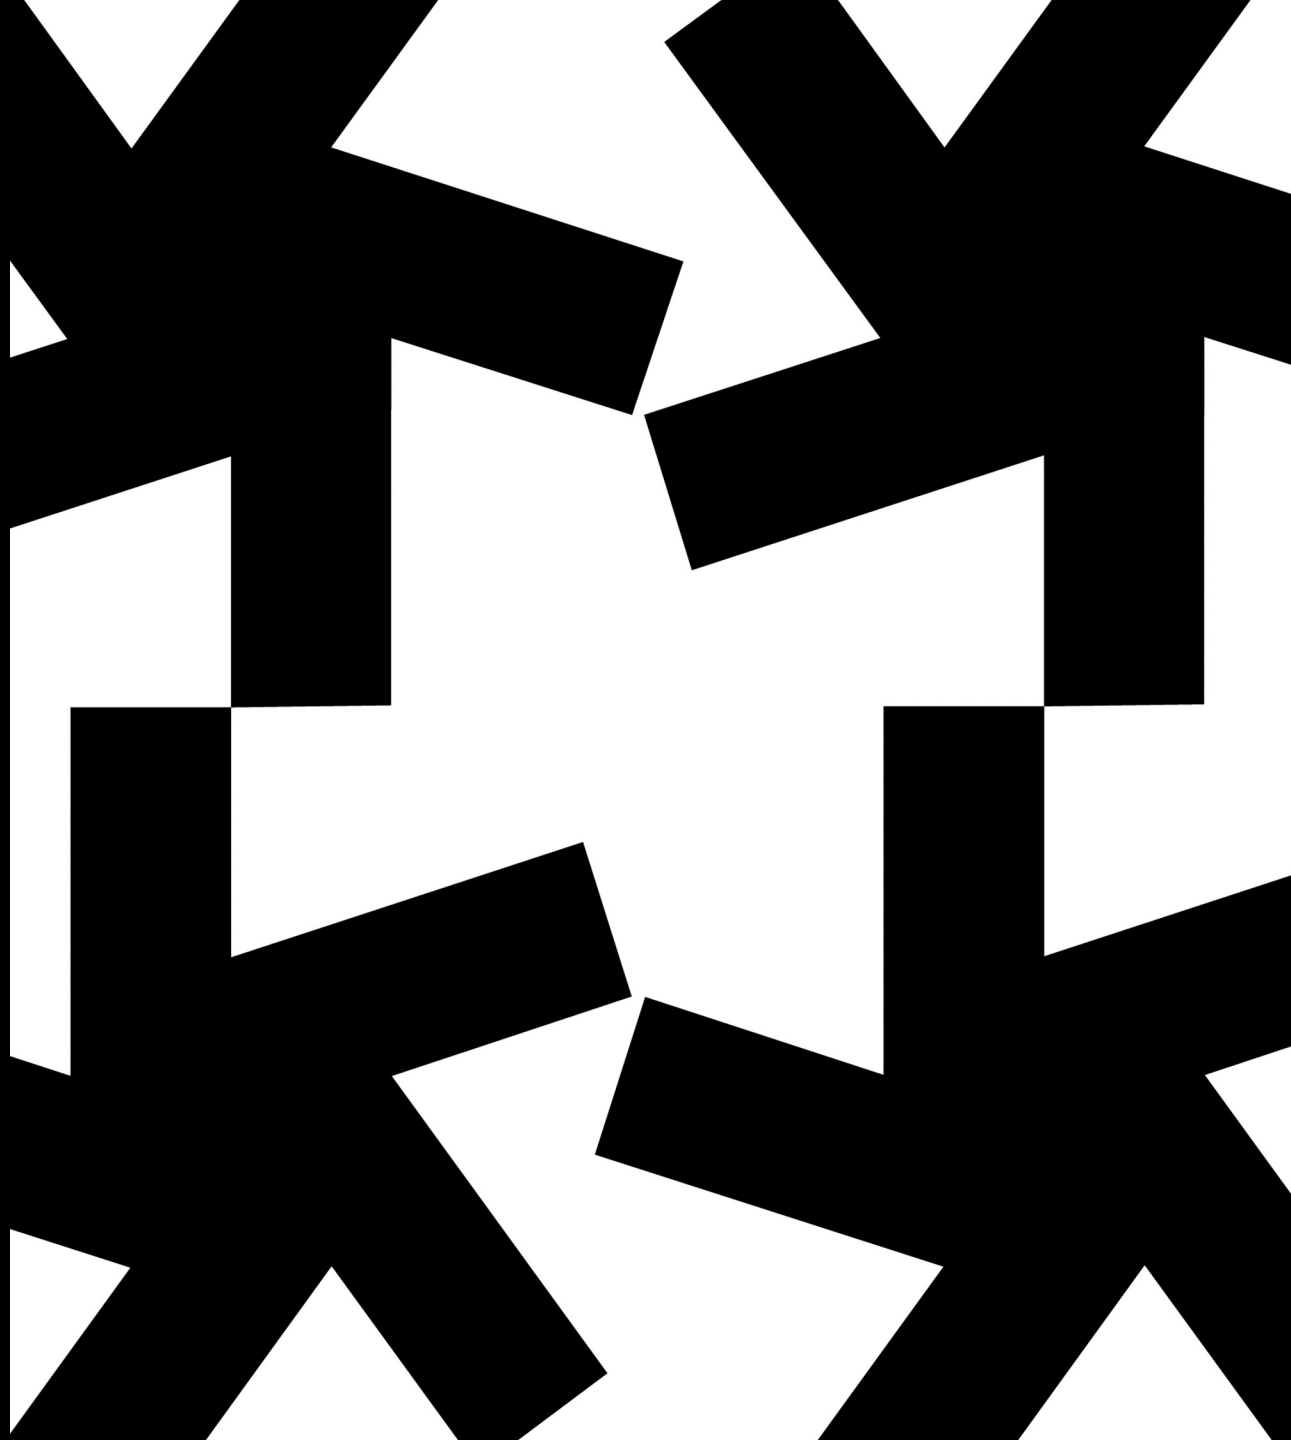
K-means asigna a todos y su centroide es una media: un punto extremo lo arrastra.

DBSCAN: quién no encaja

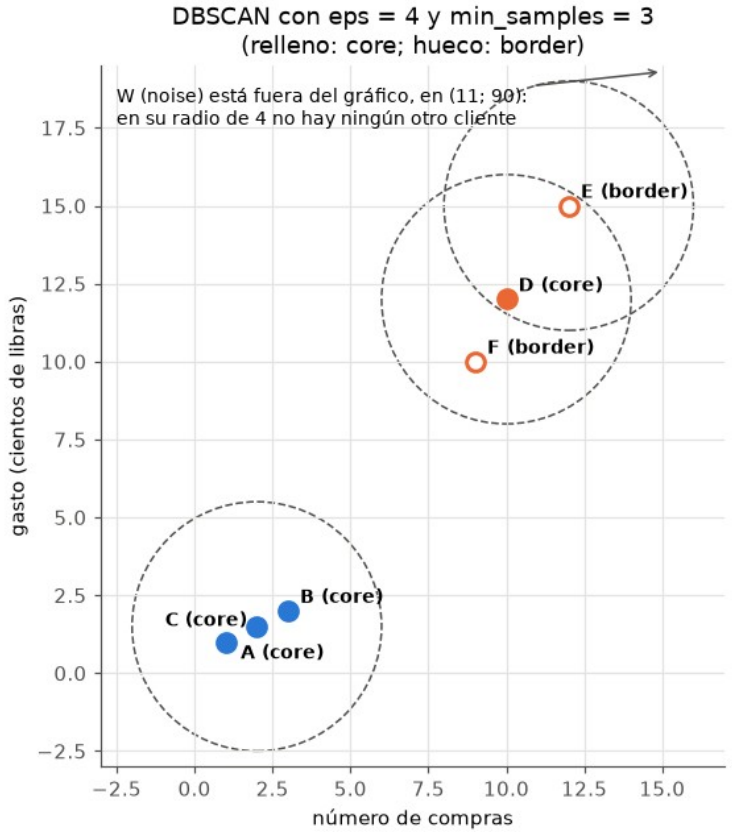
Bloque D

unie*
Universidad

Planeta Formación y Universidades



DBSCAN agrupa zonas densas y deja fuera el ruido (Density-Based Spatial Clustering of Applications with Noise)



Punto Core

Tiene al menos min_samples puntos en su radio eps. El eps es el radio máximo de distancia para considerar que dos puntos son vecinos

Punto Border

No los tiene al menos min_samples en su radio, pero está en el radio de un core

Noise (ruido)

Ni una cosa ni otra: no entra en ningún grupo

Figura 02.8 del capítulo: papeles de DBSCAN en el ejemplo pequeño.

¿Cómo elegir el eps? El 95 % tiene su 8.º vecino a menos de 0,65

Distancia de cada cliente a su 8.º vecino más cercano (5 852 clientes, variables escaladas)

la mitad de los clientes, a menos de	el 95 % de los clientes, a menos de	el 99 % de los clientes, a menos de
0,29	**0,65**	**1,07**

- min_samples = 2 × 4 variables = 8
- Zonas densas: vecinos cerca. Clientes aislados: vecinos lejos

¿Qué eps usaríais para el catálogo?

VOTAD

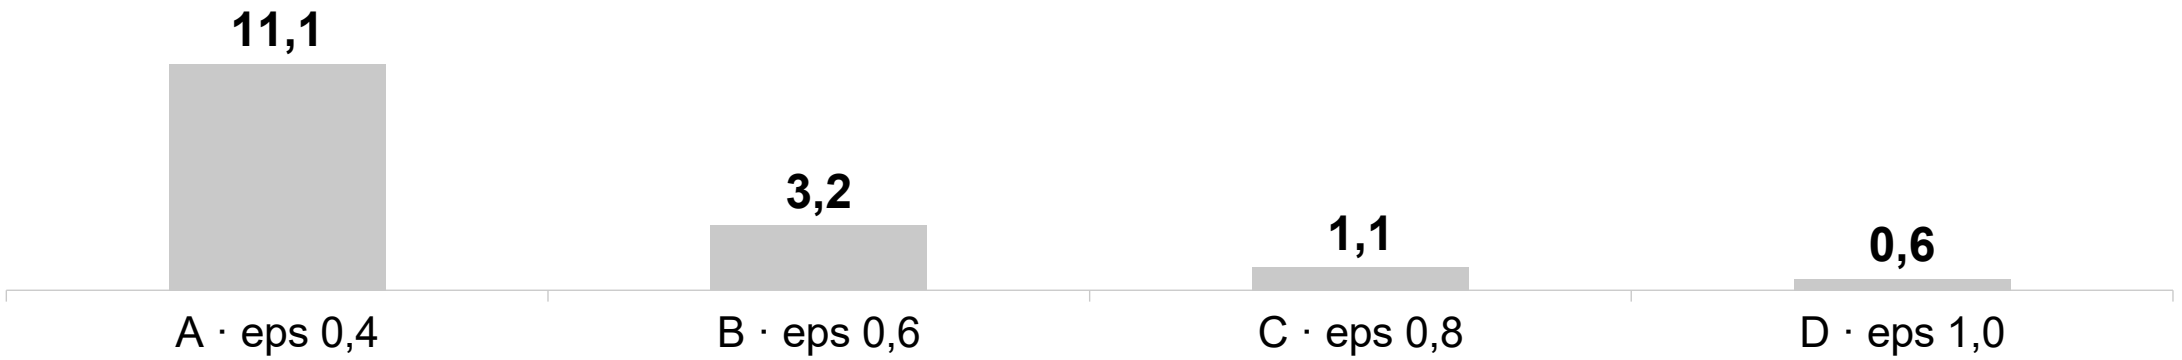
Queremos un catálogo de atípicos que alguien pueda revisar caso a caso. ¿Qué eps usaríais?

A eps = 0,4 · 650 clientes

B eps = 0,6 · 186 clientes

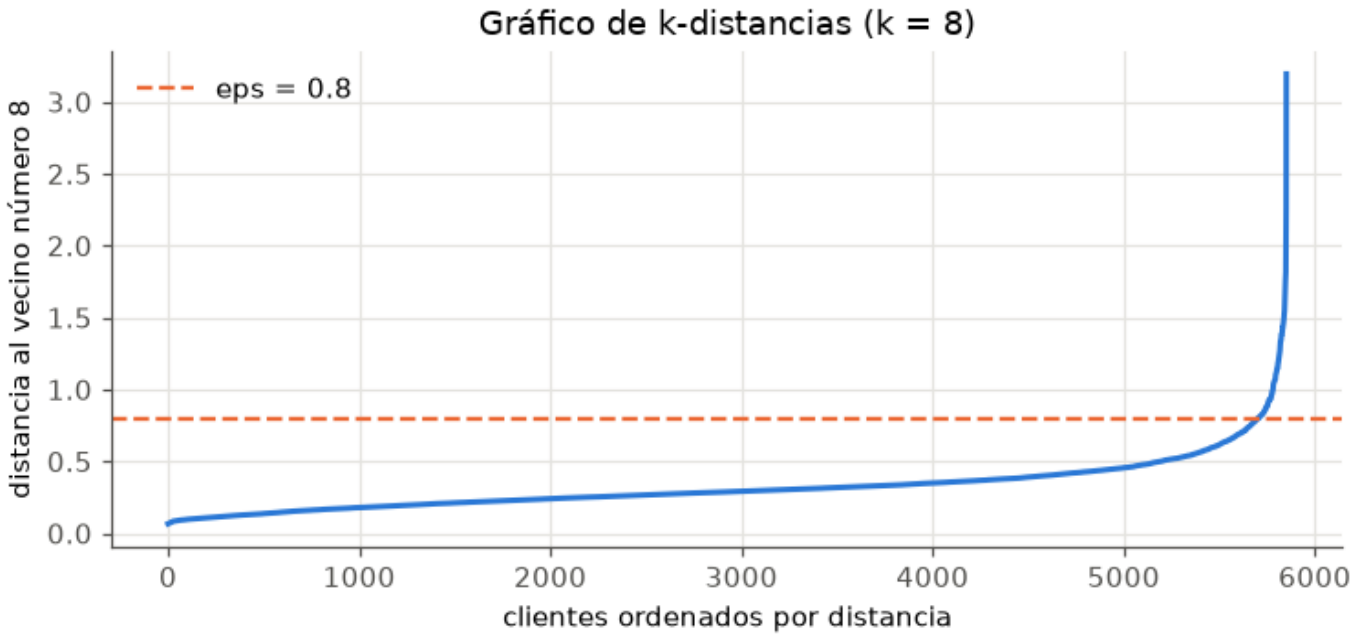
C eps = 0,8 · 67 clientes

D eps = 1,0 · 33 clientes



Clientes que quedan como ruido, en % de los 5 852, con min_samples = 8.

Con un eps razonable, todos caben en un cluster



eps	Clusters	Ruido
0,4	5	650
0,5	2	337
0,6	2	186
0,8	1	67
1,0	1	33

Figura 02.9 del capítulo: distancia al 8.º vecino, ordenada; la línea marca eps = 0,8.

Nube continua, sin huecos: K-means la divide en zonas (segmentos) y DBSCAN dice quién queda fuera (atípicos).

¿Cliente valioso o error de datos?

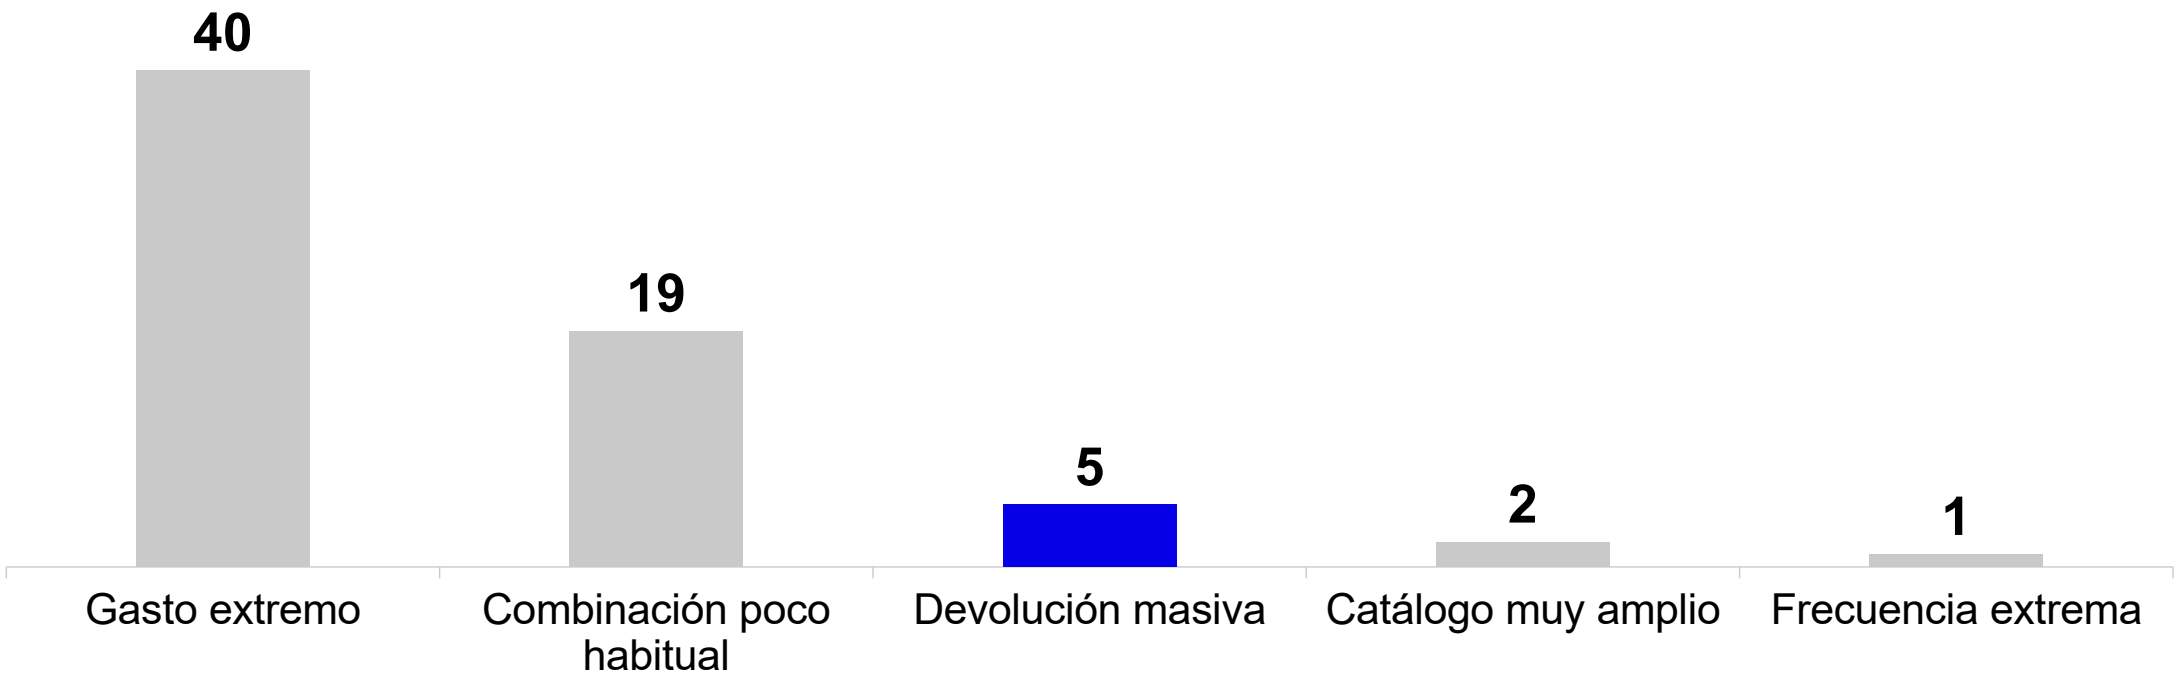
PREGUNTA AL AULA

Dos clientes que DBSCAN deja como ruido. ¿Qué es cada uno? ¿Con qué variable lo distinguís?

Cliente	Días desde la última compra	Facturas	Gasto bruto (£)	Productos distintos	Proporción devuelta
18102	1	145	580 987,04	382	0,00
16446	1	2	168 472,50	3	1,00

Vuestras respuestas

67 atípicos: 40 de gasto extremo y 5 devoluciones



Atípicos de DBSCAN (eps = 0,8; 67 clientes) por su rasgo más llamativo frente a la mediana de todos los clientes: gasto extremo = más de 20 veces la mediana; devolución masiva = devuelve más de la mitad (en azul).

Ver los segmentos con PCA

Bloque E

unie*
Universidad

Planeta Formación y Universidades

El mapa conserva el 88,4 % de la varianza

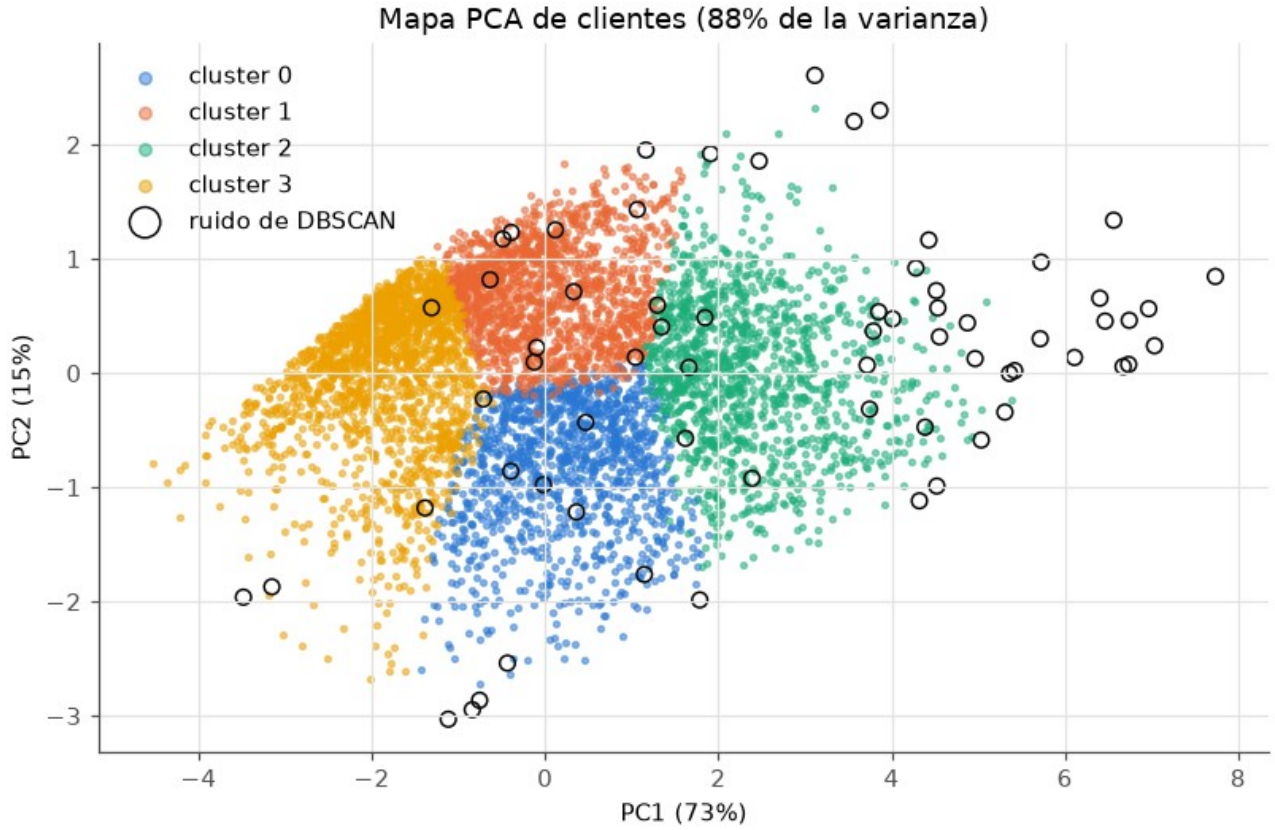


Figura 02.12 del capítulo: los 5 852 clientes, coloreados por cluster; círculos: atípicos de DBSCAN.

PCA

Resume las cuatro variables en los dos ejes en que más se diferencian los clientes

PC1 ≈ intensidad de la relación; PC2 ≈ tiempo sin comprar (leído en los pesos)

Es para ver y comunicar, no para decidir

¿Se ha equivocado DBSCAN?

PREGUNTA AL AULA

En el mapa, algunos atípicos aparecen en mitad de la nube, rodeados de clientes normales. ¿Se ha equivocado DBSCAN?

Lo que sabemos

El mapa conserva el 88,4 % de la varianza de las cuatro variables

Vuestras respuestas

De cluster a segmento

Bloque F

unie*
Universidad

Planeta Formación y Universidades

Un segmento tiene nombre, valor y una acción

Segmento	% clientes	% gasto bruto	Comportamiento	Acción (hipótesis)
Núcleo activo	21,7	73,9	Compran a menudo, mucho y variado	Cuidar y fidelizar: servicio prioritario
Recientes de baja frecuencia	21,1	8,2	Pocas compras, pero recientes	Convertir en habituales: segunda compra
Habituales en pausa	25,8	14,7	Compraban con regularidad y han parado	Reactivar antes de perderlos
Compra única antigua	31,4	3,2	Una compra pequeña hace más de un año	Bajo coste: comunicación masiva o no actuar

Porcentajes sobre los 5 852 clientes y su gasto bruto total. Nombres neutrales: describen, no juzgan.

¿Dedicamos menos recursos a la compra única antigua?

DEBATE

«Compra única antigua»: 31,4 % de los clientes y 3,2 % del gasto bruto. ¿Le dedicamos menos recursos que al resto? ¿Hasta dónde?

Invertir según el valor de cada segmento

Garantizar a todos el mismo servicio básico

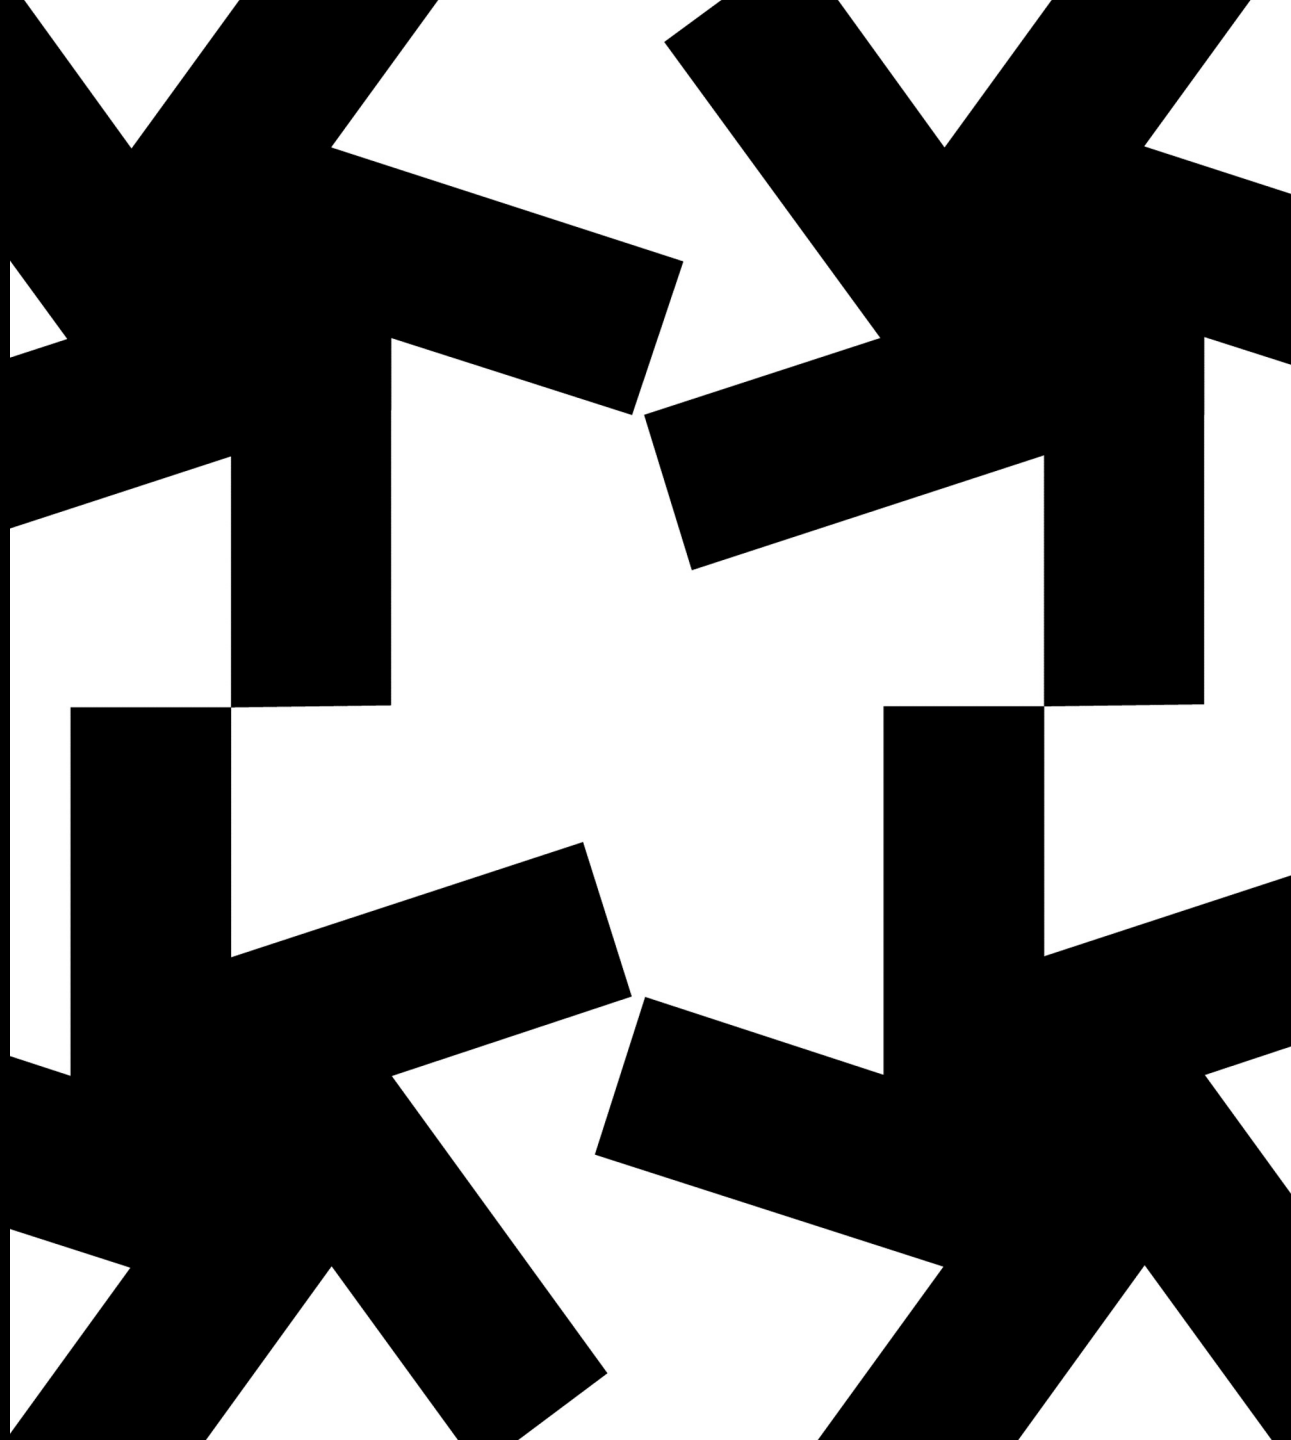
Vuestras respuestas

AI notebook

Bloque G

unie*
Universidad

Planeta Formación y Universidades



Antes de empezar

Necesitas

- Python 3 con Jupyter
- pandas, numpy y matplotlib
- scikit-learn (con scipy)
- pyarrow, para leer los .parquet

Copia junto al notebook, sin cambiarles el nombre

Fichero	Tamaño	Para qué sirve
customers.parquet	0,2 MB	La tabla de la clase 1
customers_segments_referencia.parquet	0,2 MB	Rescate y comprobar la tuya

Demo: del fichero al mapa en cinco pasos

1. Preparar X
2. K-means
3. DBSCAN
4. Mapa PCA
5. Segmentos

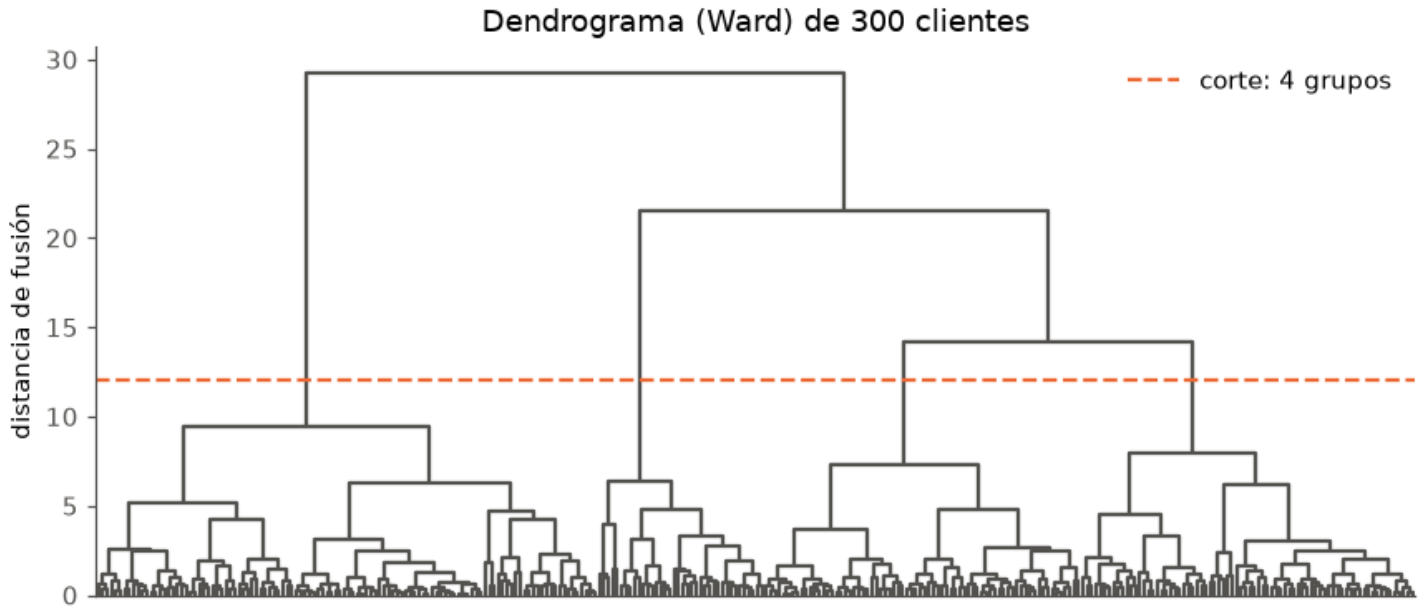


Figura 02.7 del capítulo: dendrograma (Ward) de 300 clientes; la línea corta en cuatro grupos.

Clustering jerárquico: une paso a paso los grupos más parecidos

Laboratorio: K-means, DBSCAN y segmentos

B1	Distancia y escalado	Ej. 1, 2
B2	K-means y elección de K	Ej. 3, 4
B3	Perfilar los clusters	Ej. 5
B4	DBSCAN	Ej. 6
B5	El ruido como información	Ej. 7
B6	El mapa PCA	Ej. 8
B7	De cluster a segmento	Ej. 9, 10

Entregables

salidas/customers_segments.parquet

salidas/fichas_segmento.csv

salidas/catalogo_atipicos.csv

Si te atascas

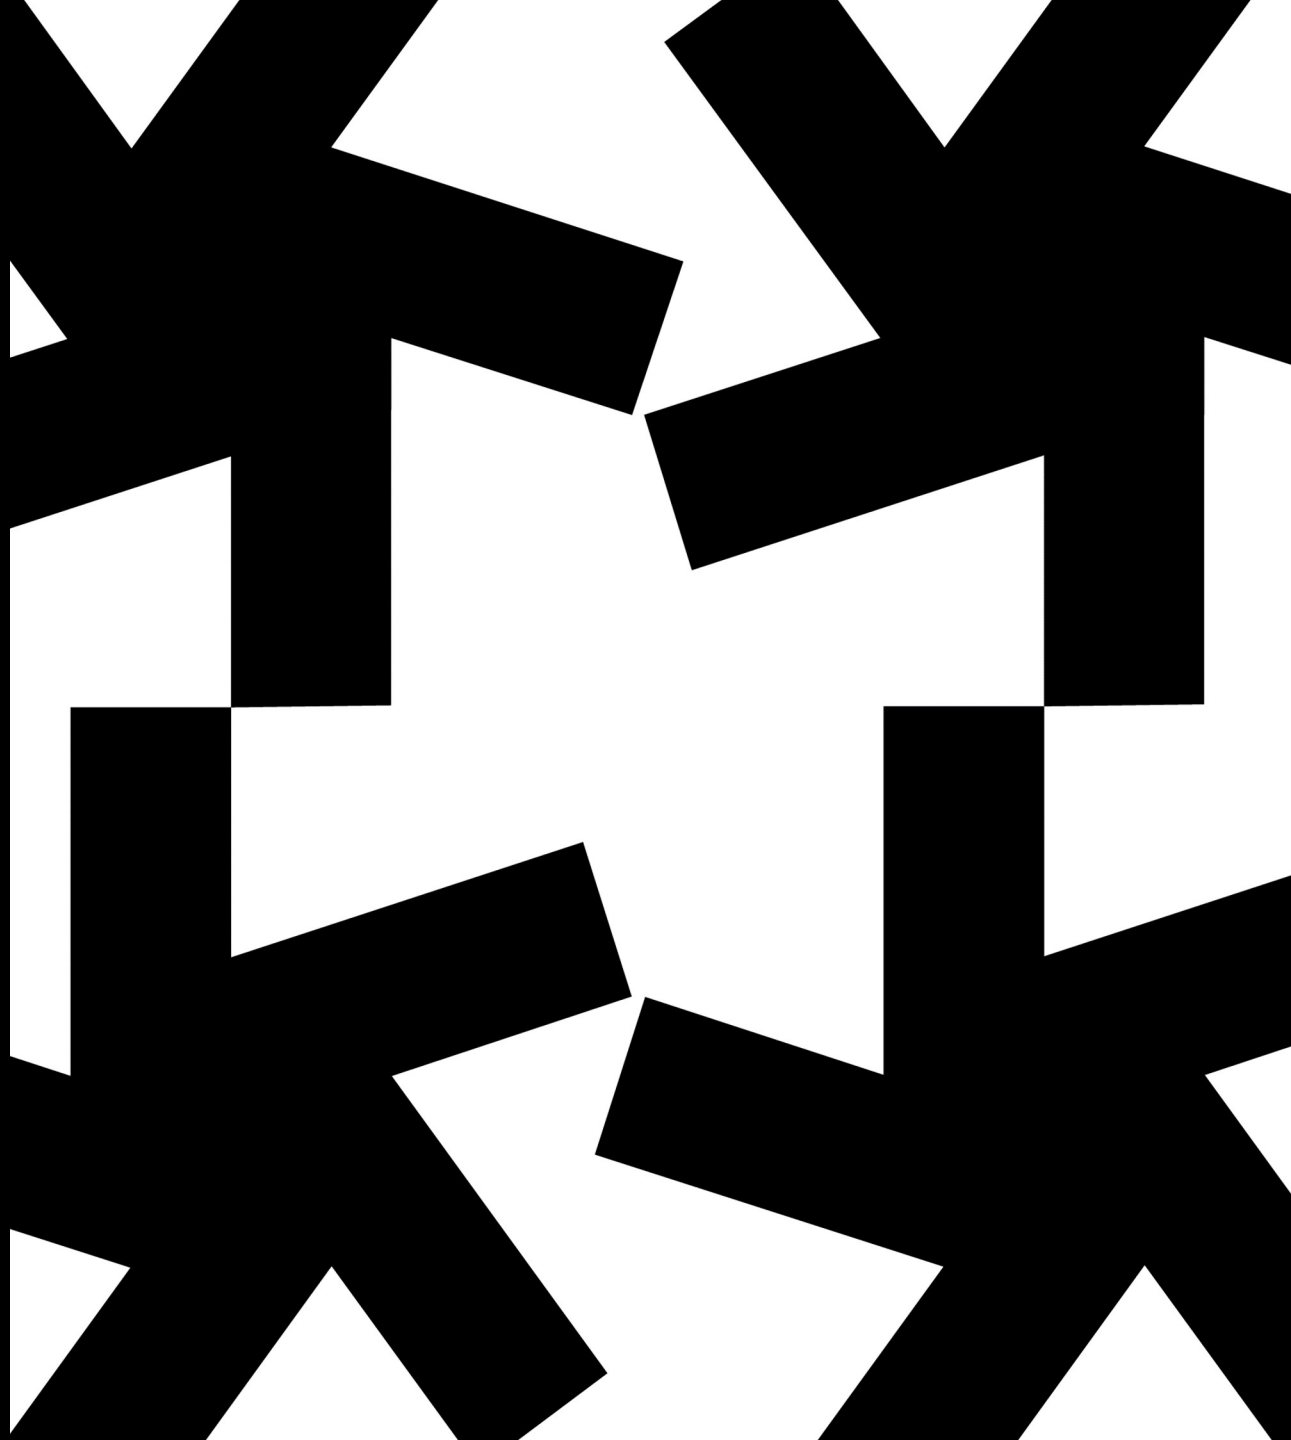
La celda de rescate de la parte siguiente: cambia USAR_RESCATE = False por True

Síntesis

Bloque H

unie*
Universidad

Planeta Formación y Universidades



Vuestro turno: de la métrica a la decisión

1. La cadena con tus palabras

Interpretación, decisión, limitación y guardrail

Añade un caso tuyo del laboratorio, con su cifra

2. La petición

¿Qué grupos propones?

¿Qué clientes no encajan y qué haces con ellos?

3. Errores frecuentes

Marca en la lista los que has cometido o esquivado, y en qué ejercicio

En la parte C del notebook. Después lo corregimos en común.

De la métrica a la decisión

Paso	En esta clase
Métrica técnica	Silhouette 0,31 con K = 4 y ARI 0,99; 67 clientes (1,1 %) de ruido; el mapa conserva el 88,4 %
Interpretación	Grupos estables pero no muy separados: zonas de una nube continua, no tipos naturales. El núcleo (21,7 % de clientes) suma el 73,9 % del gasto bruto, o el 75,2 % sin los errores
Decisión	Cuatro segmentos con nombre y acción; atípicos tratados según su motivo
Limitación	Dependen de las variables, de su transformación y de K; las acciones son hipótesis no validadas; los clientes cerca de las fronteras podrían estar en otro grupo
Guardrail	Revisar al cambiar los datos y comprobar la estabilidad; no basar decisiones individuales solo en el segmento; medir el efecto de cada acción; nombres neutrales

Volviendo a la petición

«Unos pocos grupos»

Núcleo activo

Recientes de baja frecuencia

Habituales en pausa

Compra única antigua

«Quién no encaja»

67

clientes (1,1 %) que no se parecen a nadie

- 43 grandes clientes reales (40 + 2 + 1): estrategia propia
- 19 casos raros: revisar uno a uno
- 5 errores de datos: excluir

Para discutir y lo que viene

Para discutir: elegimos una

- ¿Puede una segmentación institucionalizar desigualdades?
- ¿Qué nombres de segmento juzgan en lugar de describir?
- ¿Cómo detectaríais un grupo demográfico escondido en un segmento?
- ¿Qué uso de la etiqueta «atípico» permitiríais y cuál no?

Lo que viene

Clase 3: el customer journey, ¿dónde perdemos a los clientes?

Clases 6 y 7: el segmento vuelve en el abandono y en el valor futuro